


***Inteligência Artificial
e Computacional***

Introdução ao Aprendizado Estatístico


Predição: Regressão Simples e Múltipla

Conteudista: Moysés Nascimento



Conteúdo

- ❑ Introdução
- ❑ Regressão Linear Simples
 - ❑ Modelo, Estimação e Inferência
- ❑ Regressão Linear Múltipla
 - ❑ Modelo, Estimação e Inferência




Introdução

❑ **Regressão:** Tem por objetivo obter uma relação funcional entre uma variável dependente (Y) e uma ou mais variáveis independentes ou explicativas (X).

❑ Regressão Simples

❑ Regressão Múltipla




Regressão Linear Simples

□ Modelo

$$y_i = \beta_0 - \beta_1 X_i + e_i,$$

em que: y_i é o i-ésimo valor variável dependente; X_i é o i-ésimo valor da variável independente; β_0 é o intercepto; β_1 é o coeficiente angular e; e_i é o erro aleatório.


O erro representa todas as variações não consideradas no modelo e, além disso é considerado que o mesmo tem média igual a zero ($E(\varepsilon_i)=0$), variância constante ($V(\varepsilon_i)=\sigma^2$) e são não correlacionados ($\text{Cov}(\varepsilon_i, \varepsilon_j)=0$).



Regressão Linear Simples

- ❑ Estimação dos Parâmetros (β_0 e β_1)
 - ❑ Método dos Mínimos Quadrados
 - ❑ Adota como estimativas dos parâmetros, os valores que minimizam a soma de quadrados das diferenças entre o observado e o predito pelo modelo ajustado (reta), ou seja, o erro.

$$Z = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 X_i)^2.$$



Regressão Linear Simples

❑ Após algumas álgebras, os estimadores dos parâmetros são dados por:


$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{X} \text{ e } \hat{\beta}_1 = \frac{SPD_{XY}}{SQD_X},$$

em que: $\bar{y}$ é a média de Y; $\bar{X}$ é a media de X, $SPD_{XY} = \sum_i X_i Y_i - \frac{\sum_i X_i \sum_i Y_i}{n}$ é

a soma do produto dos desvios de X e Y e; $SQD_X = \sum_i X_i^2 - \frac{(\sum_i X_i)^2}{n}$ é a

soma de quadrados dos desvios de X.

Agora podemos apresentar o modelo ajustado: $\hat{y}_i = \hat{\beta}_0 - \hat{\beta}_1 X_i$.




Regressão Linear Simples

❑ Estimação de (σ^2)

❑ Obtido pela decomposição da soma de quadrados dos resíduos (SS_R):

$$\hat{\sigma}^2 = \frac{SS_R}{gl(SS_R)},$$


em que SS_R é a Soma de Quadrado dos resíduos ($SS_R = \sum_{i=1}^n \hat{e}_i^2$). O número de graus de liberdade é $n - 2$ visto que para obtenção da SS_R são necessários estimar dois parâmetros no modelo de regressão.



Regressão Linear Simples

- ❑ Inferências a respeito dos parâmetros (β_0 e β_1)
- ❑ Adicionar a suposição de Normalidade aos erros ($e_i \stackrel{\text{i.i.d}}{\sim} N(0, \sigma^2)$).
- ❑ Desta forma, pelo teorema da combinação linear Y_i também é normal e conseqüentemente os estimadores dos parâmetros também são normalmente distribuídos, ou seja:

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{\text{SQD}_X}\right) \text{ e } \hat{\beta}_0 \sim N\left[\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\text{SQD}_X}\right)\right].$$



Regressão Linear Simples

❑ Hipóteses (β_0)


$$\begin{cases} H_0: \beta_0 = \beta_{00} \\ H_1: \beta_0 \neq \beta_{00} \end{cases}$$

❑ Estatística de teste

$$t = \frac{\hat{\beta}_0 - \beta_{00}}{\sqrt{\hat{\sigma}^2 \left(\frac{1}{n} + \frac{X^2}{S Q D_X} \right)}}$$

❑ Decisão do teste

❑ Se $|t| > t_{(\alpha/2; n-2)}$, rejeitamos H_0 , em que $t_{(\alpha/2; n-2)}$ é o quantil $(1 - \alpha/2)$ da distribuição t de Student com $n - 2$ graus de liberdade.



Regressão Linear Simples

❑ Hipóteses (β_1)


$$\begin{cases} H_0: \beta_1 = \beta_{10} \\ H_1: \beta_1 \neq \beta_{10} \end{cases}$$

❑ Estatística de teste

$$t = \frac{\hat{\beta}_1 - \beta_{10}}{\sqrt{\frac{\hat{\sigma}^2}{S Q D_X}}}$$

❑ Decisão do teste

❑ Se $|t| > t_{(\alpha/2; n-2)}$, rejeitamos H_0 , em que $t_{(\alpha/2; n-2)}$ é o quantil $(1 - \alpha/2)$ da distribuição t de Student com $n - 2$ graus de liberdade.




Regressão Linear Simples

- ❑ Coeficiente de Determinação

- ❑ Qualidade do ajuste

$$r^2 = \hat{\beta}_1 \frac{SPD_{XY}}{SQD_Y} = \frac{SQ \text{ Re gressão}}{SQ_{Total}} [0 \leq r^2 \leq 1].$$

- ❑ Quanto mais próximo a 1 (ou a 100%) melhor o ajuste do modelo.




Regressão Linear Múltipla

❑ Modelo (Forma Matricial)

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

em que: $\mathbf{Y}$ é um vetor de dimensão $n \times 1$; $\mathbf{X}$ uma matriz de dimensão $n \times (p + 1)$, $\boldsymbol{\beta}$ um vetor de dimensão $(p + 1) \times 1$ e, $\boldsymbol{\varepsilon}$ um vetor de dimensão $n \times 1$, dados por:

$$\begin{matrix} n \\ \left[\begin{array}{c} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{array} \right]_1 \end{matrix} = \begin{matrix} n \\ \left[\begin{array}{ccccc} 1 & X_{11} & X_{21} & \dots & X_{p1} \\ 1 & X_{12} & X_{22} & \dots & X_{p2} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & X_{1n} & X_{2n} & \dots & X_{pn} \end{array} \right]_{p+1} \end{matrix} \begin{matrix} p+1 \\ \left[\begin{array}{c} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{array} \right]_1 \end{matrix} + \begin{matrix} n \\ \left[\begin{array}{c} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{array} \right]_1 \end{matrix}$$




Regressão Linear Múltipla

- ❑ Estimação do vetor de Parâmetros (β)

- ❑ Método dos Mínimos Quadrados

- ❑ Da mesma forma que anteriormente, adota-se como estimativas dos parâmetros, os valores que minimizam a soma de quadrados das diferenças entre o observado e o predito pelo modelo ajustado (reta), ou seja, o erro.

$$Z = \varepsilon^T \varepsilon = (\mathbf{Y} - \mathbf{X}\beta)^T (\mathbf{Y} - \mathbf{X}\beta).$$




Regressão Linear Simples

❑ Após algumas álgebras, o estimador do vetor de parâmetros é dados por:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y},$$

em que $(\mathbf{X}^T \mathbf{X})^{-1}$ é a inversa da matriz $\mathbf{X}^T \mathbf{X}$.

Agora podemos apresentar o modelo ajustado: $\hat{\mathbf{Y}} = \mathbf{X} \hat{\boldsymbol{\beta}}$.




Regressão Linear Simples

❑ Estimação de (σ^2)

❑ Obtido pela decomposição da soma de quadrados dos resíduos (SS_R):

$$\hat{\sigma}^2 = \frac{SS_R}{gl(SS_R)},$$

em que SS_R é a Soma de Quadrado dos resíduos ($SS_R = \mathbf{Y}^T \mathbf{Y} - \hat{\boldsymbol{\beta}}^T \mathbf{X}^T \mathbf{Y}$). O número de graus de liberdade é $n - (p + 1)$ visto que para obtenção da SS_R são necessários estimar $p + 1$ parâmetros.



Regressão Linear Múltipla


- ❑ Inferências a respeito dos parâmetros (β_j)
- ❑ Hipóteses (β_j)

$$\begin{cases} H_0: \beta_j = 0 \\ H_1: \beta_j \neq 0 \end{cases}$$

- ❑ Estatística de teste

$$t = \frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2 C_{jj}}},$$


em que C_{jj} é o elemento na posição jj da matriz $X^T X$. Especificamente,
 $V(\beta_j) = \hat{\sigma}^2 C_{jj}$.



Regressão Linear Múltipla

❑ Decisão do teste

❑ Se $|t| > t_{(\alpha/2; n-(p+1))}$, rejeitamos H_0 , em que $t_{(\alpha/2; n-(p+1))}$ é o quantil $(1 - \alpha/2)$ da distribuição *t* de *Student* com $n - (p + 1)$ graus de liberdade.




Regressão Linear Múltipla

❑ Coeficiente de Determinação Múltipla

❑ Qualidade do ajuste

$$R^2 = \frac{SQ \text{ Regressão}}{SQ \text{ Total}} = \frac{\hat{\boldsymbol{\beta}}^T \mathbf{X}^T \mathbf{Y}}{\mathbf{Y}^T \mathbf{Y}} [0 \leq R^2 \leq 1].$$

❑ Quanto mais próximo a 1 (ou a 100%) melhor o ajuste do modelo.




Regressão Linear Múltipla

- ❑ Coeficiente de Determinação Múltipla Ajustado

- ❑ Quando maior p maior seu valor.

$$\bar{R}^2 = \frac{R^2(n - 1) - p}{n - 1 - p} [0 \leq \bar{R}^2 \leq 1].$$

- ❑ Quanto mais próximo a 1 (ou a 100%) melhor o ajuste do modelo.



Regressão Linear Múltipla

- ❑ A seguir tais conceitos serão apresentados em uma aula prática, no Tutorial sobre os Modelos de Regressão Simples e Múltipla.