


***Inteligência Artificial
e Computacional***

Introdução ao Aprendizado Estatístico


Predição: Árvores de Regressão

Conteudista: Moysés Nascimento




Conteúdo

- ☐ Introdução
- ☐ Construção da Árvore de Regressão
- ☐ *Bagging*
- ☐ *Random Forest*



Introdução

- ❑ **Árvores de Regressão:** Tem por objetivo a construção de uma árvore que permita realizar previsões de uma variável dependente (Y) em função de uma ou mais variáveis independentes ou explicativas (X).




Construção das Árvores de Regressão

- ❑ Estratificação do espaço amostral (Preditor):
 - ❑ Dividir o espaço preditor em J regiões não sobrepostas, $R_1, R_2, \dots, R_J$, minimizando a soma de quadrados dos resíduos:

$$SQR = \sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2,$$

em que: y_i é o valor observado e; $\hat{y}_{R_j}$ é o valor predito para uma observação pertencente a região R_j , o qual é dado pela media dos valores observados de todos os indivíduos da região.



Construção das Árvores de Regressão

- ❑ Observação: Tais regiões são dadas por retângulos ou caixas devido a facilidade em sua construção e interpretação.






Figura: Partição realizada para prever o salário de jogadores de basquete com base na idade e no número de cestas.

Fonte: Alterada de James et al. (2014).



Construção das Árvores de Regressão

- ❑ Problema: Tarefa árdua computacionalmente inviável
- ❑ Solução: Realizar divisões recursivas binárias;
 - ❑ Seleciona-se o preditor, X_j , e o ponto de corte, T , que divide o espaço em duas regiões considerando o menor valor da Soma do Quadrado do Resíduo (SQR).




Construção das Árvores de Regressão

❑ Especificamente, particiona as regiões,

$$R_1(j, T) = \{X | X_j < T\} \text{ e } R_2(j, T) = \{X | X_j \geq T\},$$

que minimizam:


$$\sum_{i: x_i \in R_1(j, T)} (y_i - \hat{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, T)} (y_i - \hat{y}_{R_2})^2.$$



Construção das Árvores de Regressão

❑ **Exemplo:** Produção, peso de cem grãos e número de espigas de um conjunto composto de seis cultivares de milho.

Cultivares	Peso de cem grãos (PCG)	Número de espigas por planta (NES)	Produção de Grãos (P)
C1	81	14	6,16
C2	130	3	6,17
C3	141	11	6,21
C4	87	2	4,52
C5	169	11	6,62
C6	170	11	6,91



Construção das Árvores de Regressão

- ❑ Para facilitar o entendimento da construção de uma árvore de regressão, vamos ordenar o conjunto de dados por cada uma das variáveis em estudo.


Cultivares	P	NES	PCG
C4	4,52	2	87
C2	6,17	3	130
C3	6,21	11	141
C5	6,62	11	169
C6	6,91	11	170
C1	6,16	14	81

Cultivares	P	NES	PCG
C1	6,16	14	81
C4	4,52	2	87
C2	6,17	3	130
C3	6,21	11	141
C5	6,62	11	169
C6	6,91	11	170

- ❑ Primeira divisão: Valores de SQR considerando partições binárias

Variável	2	3	11
NES	0.45	1.74	3.44

Variável	81	87	130	141	169
PCG	3.44	1.87	2.05	2.11	2.65




Construção das Árvores de Regressão

- ❑ Segunda divisão: Valores de SQR considerando partições binárias

Variável	3	11
NES	0.38	0.37

Variável	81	130	141	169
PCG	0.37	0.25	0.04	0.15


- ❑ O procedimento é repetido até uma critério de parada, por favor, não ter mais de 5 indivíduos nos nós terminais.




Construção das Árvores de Regressão

□ Árvore de Regressão

Média entre o ponto de menor SQR e seu vizinho: $(2+3)/2 = 2.5$




Média entre o ponto de menor SQR e seu vizinho: $(141+169)/2=155$




Construção das Árvores de Regressão

□ Árvore de Regressão




Cultivares	Peso de cem grãos (PCG)	Número de espigas por planta (NES)	Produção de Grãos (P)
C1	81	14	6.16
C2	130	3	6.17
C3	141	11	6.21
C4	87	2	4.52
C5	169	11	6.62
C6	170	11	6.91




Construção das Árvores de Regressão

□ Árvore de Regressão





Cultivares	Peso de cem grãos (PCG)	Número de espigas por planta (NES)	Produção de Grãos (P)
C1	81	14	6,16
C2	130	3	6,17
C3	141	11	6,21
C5	169	11	6.62
C6	170	11	6.91



Construção das Árvores de Regressão

❑ *Overfitting*






Construção das Árvores de Regressão

- ❑ Poda da Árvore: Reduzir a complexidade da árvore aumentando o poder preditivo da mesma.
- ❑ Custo de complexidade da Poda

$$\sum_{m=1}^{|T|} \sum_{x_i \in R_m} (y_i - \hat{y}_{R_m})^2 + \alpha |T|,$$

em que: $|T|$ é o número de nós terminais e; α é o parâmetro de ajuste.



Construção das Árvores de Regressão

☐ Vantagens


- ☐ Fácil interpretação

- ☐ Robusta a *outliers*

- ☐ Insensível a transformações monótonas

☐ Desvantagem

- ☐ Poder preditivo




Bagging

- ❑ Obter diversas amostras *bootstrap* e considerar a média obtidas por todas as árvores (não podadas) como valor predito:


$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x).$$

- ❑ *Out-of-bag (OOB): Pode ser demonstrado que cada amostra bootstrap possui em média 2/3 das observações. As demais, 1/3, não utilizadas no ajuste, são referidas como observações Out-of-bag e utilizadas para predição possibilitando obter Erro Quadrático Médio (EQM) de predição.*




Random Forest

- ❑ Variação do *bagging*
 - ❑ Não são utilizadas todas as variáveis na construção da árvore.
 - ❑ Árvore de regressão: $(p/3)$,
em que p é o número de variáveis.




Bagging versus Random Forest

<i>Bagging</i>	<i>Random Forest</i>
Variável mais importante quase sempre no topo	Variável mais importante não estará sempre no topo
Árvores semelhantes	Árvores diferentes
Predições altamente correlacionadas	Predições menos correlacionadas
Pouca redução da variabilidade	Maior redução da variabilidade




Importância de variáveis

- ❑ Avaliada pelo decréscimo na SQR quando retira-se a variável do ajuste.



Fonte:

<https://stats.stackexchange.com/questions/448487/random-forest-variable-importance-in-r-and-python>



Árvores de Regressão

- ❑ A seguir tais conceitos serão apresentados em uma aula prática, no Tutorial sobre Árvores de Regressão.