


Aprendizado de Máquinas

Rodolpho Neves



Universidade Federal de Viçosa

Reitor

Demetrius David da Silva

Vice-Reitora

Rejane Nascentes



Diretor

Francisco de Assis de Carvalho Pinto

Campus Universitário, 36570-900, Viçosa/MG

Telefone: (31) 3612 1251

Layout: Ana Luísa Medeiros e Stéfany Peron

Editoração Eletrônica: Ana Luísa Medeiros

Edição de conteúdo e CopyDesk: João Batista Mota



Significado dos ícones da apostila

Para facilitar o seu estudo e a compreensão imediata do conteúdo apresentado, ao longo de todas as apostilas, você vai encontrar essas pequenas figuras ao lado do texto. Elas têm o objetivo de chamar a sua atenção para determinados trechos do conteúdo, com uma função específica, como apresentamos a seguir.



DESTAQUE: são definições, conceitos ou afirmações importantes às quais você deve estar atento.



GLOSSÁRIO: Informações pertinente ao texto, para situá-lo melhor sobre determinado termo, autor, entidade, fato ou época, que você pode desconhecer.

SAIBA MAIS: se você quiser complementar ou aprofundar o conteúdo apresentado na apostila, tem a opção de links na internet, onde pode obter vídeos, sites ou artigos relacionados ao tema.



PARA REFLETIR: vai fazer você relacionar um tópico a uma situação externa, em outro contexto



Exercícios Propostos: são momentos pra você colocar em prática o que foi aprendido



Currículo

Rodolpho Vilela Alves Neves

Possui graduação (2011) em Engenharia Elétrica pela Universidade Federal de Viçosa, mestrado (2013) e doutorado (2018) também em Engenharia Elétrica pela Universidade de São Paulo. Entre 2015 e 2016, foi pesquisador visitante na Aalborg University, Dinamarca.

Atualmente, é professor adjunto no Departamento de Engenharia Elétrica da UFV. Atua no tema de controle inteligente de sistemas dinâmicos, principalmente no controle de geração distribuída e de sistemas de energia.

Contato: rodolpho.neves@ufv.br



1. Introdução

Aprendizado de máquina é o termo que define a capacidade de um software otimizar, maximizar ou minimizar determinado parâmetro de desempenho dado um conjunto de dados previamente conhecido.

O aprendizado humano, que também é feito baseado em exemplos ou em dados previamente conhecidos, resulta na aquisição de habilidades. Já no aprendizado de máquina, o resultado é a capacidade de prever resultados baseados nos exemplos que já foram apresentados à máquina. O aprendizado de máquinas pode, automaticamente, detectar padrões em bancos de dados e utilizar o poder de generalização para prever saídas futuras ou outras informações de interesse.

Apesar de ser um tópico em alta, o aprendizado de máquinas é datado da Segunda Guerra Mundial, quando máquinas foram criadas para quebrar os códigos de comunicação do exército alemão. Depois disso, o assunto não avançou muito, por causa da limitação de processamento dos computadores. Hoje em dia, com a alta capacidade de processamento dos computadores e a otimização dos hardwares dos processadores, o assunto aprendizado de máquinas está em alta. Além disso, nunca houve essa imensa quantidade de dados gerados pela humanidade - muito disso graças aos avanços da eletrônica e da informática de sensores e da modernização da internet e das redes de comunicação mundial.

Grandes empresas, como Google, Apple, Facebook e Amazon, conseguem levantar cada vez mais dados sobre comportamento, compras e interesses de seus usuários. Outros agentes que estão atrás destes dados são partidos políticos e empresas de menor porte. Tais dados são utilizados para identificar tópicos de interesse, influenciadores, tendências de determinados grupos sociais, seja no processo de predição ou de tomada de decisão.



Ao ensinar a máquina, cada iteração de treinamento gera um novo modelo, uma função $y = f(x)$, na qual x são as entradas, como escolhas do usuário, horário de acesso ou outros comportamentos dos indivíduos, e y é o resultado que se deseja modelar. A máquina estabelece uma função entre as entradas do modelo e a saída, por meio do modelo $y = f(x)$. A função f será otimizada pelas iterações durante a otimização do modelo.

Existem duas principais aplicações que utilizam a otimização de uma função usando o aprendizado de máquina:

1. **Predição:** quando os valores de entrada da função são conhecidos e é necessário estimar o valor da saída. O objetivo aqui é somente encontrar o valor de saída, e não a relação da saída com cada uma das entradas.
2. **Inferência:** quando a relação entre entrada e saída é importante. Ao estabelecer a relação entre entrada e saída é possível dizer como a saída se comporta em função de alguma variação na entrada.

A escolha do melhor modelo será feita baseada no tipo de problema que está sendo resolvido. Por exemplo, em problemas de predição, aquele que apresentar a melhor precisão de predição será o melhor modelo. Já em problemas de inferência, o melhor que conseguir interpretar as tendências será o modelo que resolve melhor o problema.

O método de aprendizado descreve a metodologia por trás do aprendizado da máquina. Existem duas abordagens: a paramétrica e a não paramétrica.

- **Abordagem paramétrica:** é feita assumindo uma função matemática na qual os parâmetros serão ajustados de acordo com o processo de treinamento.

- **Abordagem não paramétrica:** não há uma forma definida de função, objetivando uma aproximação mais precisa do resultado.

Comparando os dois métodos de treinamento, a abordagem paramétrica é a mais interpretável, a menos precisa e necessita de menos dados para ser feita. Por outro lado, a abordagem não paramétrica é a mais precisa, mas necessita de uma quantidade de dados muito maior. Portanto, a escolha do método de aprendizado vai depender do tipo de problema em questão.

Os tipos de aprendizado são separados em supervisionado e não supervisionado. O primeiro é caracterizado pelo uso do par entrada e saída. Nele, o aprendizado da máquina consiste em mapear a relação entrada e saída do problema, sabendo quais são os valores de saída que devem ser alcançados para cada entrada do banco de dados.

Já o aprendizado não supervisionado é mais utilizado para identificar grupos ou padrões dentro de um conjunto de dados. Aqui não há dados de saída para auxiliar no processo de treinamento da máquina e a maioria das informações é fornecida pelo conjunto de entrada do problema.

Podemos citar alguns algoritmos para aprendizado supervisionado, como: regressão linear, redes neurais artificiais, máquina de vetor de suporte (SVM, do inglês support vector machine), etc.

O modelo apresentado na Figura 1 é capaz de classificar diferentes itens, de acordo com uma imagem (entrada) e seus rótulos (saídas desejadas). A partir de iterações durante a etapa do treinamento supervisionado, o modelo aprende as características relacionadas a cada entrada e atribui um rótulo às entradas que apresentam aquelas características. Com isso, o modelo é capaz de inferir qual é o rótulo de itens que não foi mostrado durante a fase de treinamento, mas tem características semelhantes às das entradas rotuladas.




Figura 1 – Classificação de itens rotulados com aprendizagem supervisionada

A Figura 2 apresenta um exemplo de modelo em que foi aplicado o aprendizado não supervisionado. Nesse caso, o algoritmo agrupou (clusterizou) as entradas com características semelhantes, sem rotular cada uma. Geralmente, antes do processo de treinamento desse tipo de modelo, é necessário informar a quantidade de grupos que devem ser agrupados, para que o algoritmo consiga separar de maneira mais precisa cada uma das entradas.

Dentre os algoritmos para aprendizado não supervisionado, podemos citar: clusterização, K-means, modelos de cadeias markovianas (HMM, do inglês *Hidden Markov Models*), mapas auto-organizáveis etc.




Figura 2 – Clusterização de itens com aprendizagem não supervisionada

1.MODELO DE APRENDIZADO DE MÁQUINA

A construção de um modelo de aprendizado de máquina pode ser dividida em 7 etapas:

1. Formulação do problema
2. Seleção e adaptação do banco de dados
3. Pré-processamento do banco de dados
4. Separação do banco de dados em dados de treinamento e dados de validação
5. Treinamento do modelo com os dados de treinamento
6. Validação do modelo e estimativa de desempenho com os dados de validação
7. Implementação do modelo para a aplicação

1.1. Formulação do problema


Consiste em converter o problema real em um problema estatístico, definir o que são os dados de entrada e os de saída e decidir se o problema será de inferência ou de predição. Vamos utilizar o exemplo de uma empresa que deseja construir um modelo para melhorar as vendas de uma loja. A formulação do problema pode ser aumentar a quantidade de produtos comprados por um determinado perfil de cliente. Com base nos dados de perfil dos clientes (sexo, idade, religião, estado civil, gasto médio na loja, etc.) e de compras (produtos, gasto médio por compra, ocasião, etc.), é possível criar um modelo que relacione produtos que eles também gostariam de comprar quando estivessem na loja.

1.2. Seleção e adaptação do banco de dados

É feita transformando os dados adquiridos do problema em um banco de dados útil para o modelo. Por exemplo, o produto que o cliente comprou (camisa manga longa, camisa manga curta, camiseta casual e camiseta regata) pode ser transformado para duas entradas, como: tipo de produto (camisa e camiseta) e característica do produto (manga curta, manga longa, casual e regata).

1.3. Pré-processamento do banco de dados

Consiste em retirar inconsistências do banco de dados, que podem ser valores em branco, valores com especificações erradas, valores muito acima ou muito abaixo da maioria dos outros



(outliers). Outra ação feita durante a etapa de pré-processamento é a transformação de dados, como dados categóricos em dados numéricos e a identificação de variáveis que realmente agregam ao modelo. No caso do exemplo da loja, entre os dados **aquisitados** dos clientes podemos ter o estado civil: solteiro, casado, divorciado e viúvo. Estes dados podem ser transformados em dados numéricos: 1 – solteiro, 2 – casado, 3 – divorciado e 4 – viúvo. Na seleção das variáveis, pode ser que os dados de religião não são relevantes, ou causam pouco impacto, para o modelo. Nesse caso, eles poderiam ser descartados, diminuindo a quantidade de dados que devem ser processados durante o treinamento.

1.4. Separação do banco de dados em dados de treinamento e dados de teste

Os dados de teste são aqueles que serão apresentados ao modelo durante a fase de treinamento. É com base nestes dados que o modelo deve identificar padrões de comportamento e estabelecer as relações entre as entradas e as saídas. Já os dados de validação são compostos pelos que restaram no banco de dados e não foram apresentados durante a etapa de treinamento. Ao apresentar os dados de validação ao modelo treinado, é possível checar se ele consegue generalizar os resultados das saídas e o quanto ele pode fazer isso. Geralmente, a divisão do banco de dados entre dados de treinamento e de validação depende do tamanho do banco de dados e é feita em torno de 70% e 30% (dito 70/30) até 90/10.

1.5. Treinamento do modelo com os dados de treinamento

Durante esta fase, ocorre o ajuste da função para que dado um conjunto de variáveis de entrada, a saída seja a equação. O modelo do aprendizado de máquina pode ser uma rede neural, um sistema nebuloso (fuzzy) ou uma máquina de vetor de suporte. Cada um desses modelos tem vantagens e desvantagens, que vamos trabalhar neste material.

1.6. Validação do modelo e estimativa de desempenho com os dados de validação

Nesta etapa, são apresentados os dados de validação para o modelo ajustado e levantadas as métricas de desempenho do modelo, comparando as respostas preditas com aquelas esperadas do banco de dados. Com essas métricas, é possível classificar e escolher quais são os melhores modelos que serão implementados.

1.7. Implementação de modelo para a aplicação

Por último, a etapa de implementação é quando vamos aplicar o modelo construído para resolver o problema. No caso da loja e na oferta de produtos para determinados perfis de consumidores, a implementação deste problema pode ser feita no programa do caixa. Ao entrar com os dados do usuário e a lista de produtos que ele quer comprar, o modelo implementado propõe ao colaborador do caixa que ofereça outros produtos indicados ao cliente.



2. Dados para Treinamento de Modelos

Problemas de aprendizado de máquina são aqueles relacionados às tarefas que são apresentadas na forma de conjuntos de casos ou exemplos, ao invés de regras predefinidas. Estes tipos de problemas são encontrados em várias áreas, desde a engenharia (aplicados à robótica, reconhecimento de imagens, vozes, textos) até à medicina (aplicados às imagens médicas, diagnósticos e no auxílio à tomada de decisões).



O processo de aprendizado da máquina consiste em encontrar relações entre conjuntos de dados de entrada e suas respectivas saídas conhecidas, utilizando somente os exemplos fornecidos para descobrir a relação entre eles. Por exemplo, dado um número de imagens de exames para diagnóstico da natureza de um tumor e todos os diagnósticos para as respectivas imagens, a máquina deve utilizar esses dados para criar um conjunto de regras que resultará em diagnósticos para outras imagens que não foram apresentadas anteriormente. As imagens e os diagnósticos conhecidos apresentados para a máquina são chamados de dados de treinamento.

Portanto, o objetivo de um modelo de aprendizado de máquina é estabelecer relações entre as entradas e saídas conhecidas para prever uma saída para um conjunto de dados de entradas que não foram apresentadas anteriormente. Se a máquina conseguir bom desempenho nas novas atribuições de diagnóstico, dizemos que ela atingiu a capacidade de generalização.

1. TIPOS DE DADOS

Os tipos de dados que podem ser tratados em problemas de aprendizado de máquina são os dados qualitativos (ou categóricos) e os quantitativos.

1.1. Dados qualitativos ou categóricos

São aqueles que não assumem valores numéricos e se dividem em diferentes variações:

- **Nominal:** os dados não são ordenados. Exemplo: gênero, estado civil, religião, nacionalidade, etc.
- **Ordinário:** os dados obedecem a uma ordem ou determinada escala. Exemplo: tamanho de roupa (pequeno, médio e grande) e meses do ano (janeiro, fevereiro, março, etc.).

1.2. Dados quantitativos

São os dados que são caracterizados por serem medidos por números. Eles podem ser:

- **Discretos:** os dados que representam valores contáveis e determinados. Exemplo: idade em anos (do 0 ao 130, contado de 1 em 1) e número de marchas em um carro (1ª à 6ª e ré).
- **Contínuos:** são dados numéricos que podem representar qualquer quantidade dentro de um determinado intervalo. Exemplo: altura e peso de uma pessoa.

De posse dos dados e sabendo identificar cada um deles, podemos descrever estatisticamente utilizando ferramentas estatísticas. As ferramentas estatísticas podem ser classificadas entre descritivas e de inferências.

- a. **Ferramentas descritivas:** nos ajudam a organizar, mostrar e descrever dados utilizando tabelas, gráficos e medições resumidas dos dados. São elas:
 - Medidas de tendência central:

- Média
 - Mediana
 - Moda
 - Medidas de dispersão:
 - Intervalo
 - Desvio padrão
 - Distribuição de frequências
 - Histogramas
- b. **Ferramentas estatísticas de inferência:** consistem em métodos que nos auxiliam na tomada de decisão ou em previsões a partir de resultados estatísticos. Elas podem ser:
- Teste de hipótese
 - ANOVA
 - Teste de Chi-Quadrado
 - Regressão

É interessante conhecer estas ferramentas e saber interpretá-las para ter certeza se o banco de dados do problema de aprendizado de máquinas conta com dados significativos e de qualidade para encontrar a solução do problema.

2. PREPARAÇÃO DE DADOS

A preparação dos dados para aplicação de aprendizado de máquinas começa por uma inspeção no banco de dados do problema. Inicialmente, é necessário verificar a qualidade dos dados utilizando algumas ferramentas estatísticas descritivas.

O primeiro passo é conhecer as variáveis do banco de dados. Elas são descritas pelos nomes, características ou intervalos de valores máximos e mínimos. Entre as variáveis qualitativas pode haver dados ausentes (em branco) ou inválidos (que não pertencem a nenhuma das descrições da variável).




Outra verificação que deve ser feita é com relação aos dados válidos do banco de dados. Algoritmos de aprendizado de máquina podem ser ajustados como modelos tendenciosos se os dados fornecidos para treinamento forem tendenciosos. Por isso, é interessante que o especialista que está manipulando os dados para o ajuste do modelo esteja ciente da distribuição desses dados no intervalo de interesse, tratando dados destoantes ou até excluindo dados excessivos em intervalos com muito mais dados válidos do que em outros.

Iniciando pelos dados destoantes (*outliers*), o especialista deve verificar se existem dados que fogem dos valores típicos do banco de dados. O *outlier* pode ocorrer por erros de inserção, ruídos de medição ou conversão errônea de unidades. Por exemplo, valores reais com decimais, como: 1,3 pode ser inserido no banco de dados como 13. Este tipo de dado absurdo muda a descrição estatística do banco de dados. Uma maneira de identificar outliers é comparando o desvio padrão do banco de dados. Usualmente, valores maiores do que a $\mu + 3\sigma$ (na qual μ é a média e σ é o desvio padrão da variável) é um *outlier*. Isso também vale para valores menores que $\mu - 3\sigma$. Se restar dúvidas que este valor não corresponde a um valor do banco de dados, deve-se realizar o treinamento com e sem o valor em questão.

- **Exemplo**

Considere os dados de pacientes em um consultório de um nutricionista, conforme mostrado a seguir.



Nome	Sexo	Idade	Altura (m)	Peso (kg)	Consumo de refrigerante (L/semana)
Bárbara	F	25	1,65	59,6	04
Danilo	M	32	1,70	96	1,2
Gabriela	F	51	1,62	55,4	0,1
Joaquim	M	35	1,57	60,0	1,0
Melina	F	63	1,75	70,0	0,6
Patrick	M	46	1,80	103,0	1,3
Tatiane	F	75	1,52	50,3	0,0

Ao analisar os dados da planilha, o nutricionista constatou que havia algo estranho com alguns valores. A média de consumo de refrigerante durante a semana estava resultando em 1,171 L/semana e o desvio padrão de 0,853 L/semana. Fazendo uma comparação com os dados da tabela, o nutricionista verificou que Bárbara estava registrada com um valor de consumo semanal de refrigerante muito acima do normal (média mais três desvios padrão). Desconsiderando os dados de Bárbara, a média e o desvio padrão do consumo de refrigerante foram 0,7 e 0,467 L/semana. Comparando os dados anotados com a tabela informada, o nutricionista percebeu que, ao digitar os valores no computador, não foi informada a vírgula no consumo de refrigerante da paciente Bárbara.

Em bancos de dados, são comuns linhas de planilhas com dados ausentes ou em branco. Isso acontece por falta de preenchimento no momento da aquisição ou, até mesmo, por um dado corrompido. Estes dados precisam ser tratados, porque muitos algoritmos de aprendizado de máquina não conseguem processar a falta de informação. Duas formas de tratar esse tipo de problema é a exclusão da linha do banco de dados ou inserção de dados nulos ou interpolados para completar a linha.

A maneira como o problema será tratado depende muito do tamanho do banco de dados: se for grande é melhor excluir a linha; mas se for pequeno, talvez não seja possível a exclusão da linha e você tenha que completar os dados com zeros, valores médios ou alguma categoria que aparece com maior frequência, dependendo da aplicação a que se destina o modelo.

3. CONDICIONAMENTO DE DADOS PARA PROBLEMAS APRENDIZADO DE MÁQUINAS

Depois de analisar o banco de dados e tratar as possíveis inconsistências, é hora de verificar quais variáveis serão utilizadas ou descartadas para o treinamento do algoritmo de aprendizado de máquinas. As variáveis de um problema podem ser altamente correlacionadas ou não, dependendo do problema em questão. Algumas formas de verificar se as variáveis se relacionam é analisar a relação gráfica entre as variáveis independentes (entradas) e as variáveis dependentes (saídas) e analisar o coeficiente de correlação linear entre elas.

A análise gráfica é feita por meio do diagrama de dispersão entre as variáveis e mostra se as elas têm uma relação linear, logarítmica, exponencial ou se não há relação (Figura 3).




Figura 3 – Diagrama de dispersão de relação entre entrada e saída com relação linear, logarítmica, exponencial e sem relação



A análise do coeficiente de correlação linear é feita por meio da matriz de correlação. Nela, todas as variáveis são analisadas duas a duas e uma matriz é montada com os resultados. Cada resultado, que vai de -1 a 1, indica a correlação entre as variáveis. Quanto mais próximo de 1, maior correlação positiva (se uma das variáveis aumenta, a outra aumenta). Quanto mais próximo de -1, maior a correlação negativa (se uma das variáveis aumenta, a outra diminui). Caso o coeficiente de correlação seja próximo de zero, a correlação entre as variáveis é muito pequena ou não há correlação entre elas.

Como a maioria dos algoritmos de aprendizado de máquina não consegue processar dados em brancos, eles também não são muito bons para realizar análise de variáveis mistas, qualitativas e quantitativas, em um mesmo problema. Uma das maneiras de contornar esta limitação é transformar a variável categórica em variável *dummy* que são as variáveis binárias que representam todos os valores daquela categoria. Por exemplo, em uma tabela que contenha a variável sexo, o valor de entrada pode ser “masculino”, “feminino” ou “não declarado”. Neste caso, ao transformar a variável sexo em uma variável *dummy*, ela passa da dimensão 1 para a dimensão 3, podendo ser (1,0,0), (0,1,0) ou (0,0,1).


Assim, a variável categórica influencia no modelo como característica presente ou ausente. Repare que quanto maior o número de valores possíveis na categoria, maior o número de variáveis *dummies* a ser utilizadas.



Cuidado com as variáveis qualitativas nominais e ordinárias e as variáveis *dummies*. Se a variável nominal for codificada em ordem, 1, 2, 3, ..., o modelo pode entender que as categorias da variável podem ter uma ordem crescente.

Por último, algumas considerações devem ser feitas quando se deseja selecionar as variáveis mais interessantes do banco de dados para a construção de um modelo. Estas considerações são:

- Se uma das variáveis tem apenas um valor em todo o banco de dados, talvez seja interessante remover esta variável, porque ela não vai acrescentar informações ao modelo. Por exemplo, em um banco de dados em que o valor é 1000 para toda a coluna de uma determinada variável.
- Se uma das variáveis tem muitos dados ausentes e não faz sentido anular ou interpolar estes dados. Por exemplo, em um banco de dados com 800 entradas, para determinada variável apenas 100 valores foram preenchidos e 700 valores estão em branco.



4. EXTRAÇÃO DE CARACTERÍSTICAS

A capacidade de generalização do modelo de aprendizado de máquinas é adquirida durante o treinamento, que nada mais é do que o ajuste de parâmetros de uma função matemática. A escolha dos parâmetros do modelo pode ser otimizada quando é utilizado o menor conjunto de variáveis de entrada para o aprendizado da máquina, sem que o modelo perca desempenho em relação a um conjunto maior de variáveis. Com intenção de otimizar o aprendizado adquirido pela máquina, utilizamos a extração de características do conjunto de entradas dos exemplos apresentados ao modelo na fase de treinamento.

O conjunto de variáveis de entrada pode ser reduzido ao aplicar alguns métodos de extração de características das variáveis originais. Algumas das técnicas mais utilizadas na extração de características para treinamento de modelos de aprendizado de máquinas são:

- **Uniformização (*standardization*):** variáveis de entrada podem ter diferentes escalas de medição, embora possam ser comparáveis. Com isso, é possível que sejam comparadas, somadas ou subtraídas, desde que estejam em escalas uniformes. Um dos métodos clássicos de fazer esta uniformização das variáveis é realizar a centralização e escalonamento dos dados, aplicando a fórmula , na qual $\bar{x}$ é o valor uniformizado, x é o valor original da variável, $\bar{x}$ é a média dos valores de x e s é o desvio padrão em relação à média .
- **Normalização (*normalization*):** considere, por exemplo, uma matriz que representa uma determinada imagem. A normalização realiza uma divisão dos valores de cada elemento da matriz pela norma da matriz, buscando limitar os valores dos elementos para valores entre -1 e 1. Matematicamente, temos que M , na qual M é a matriz com os valores que representam a imagem, $\|M\|$ é a norma da matriz e M_{norm} é a matriz normalizada.
- **Melhoramento do sinal:** Consiste em melhorar a relação sinal-ruído do sinal de entrada, aplicando filtros de rejeição de ruídos, suavização ou de nitidez. A Transformada de Fourier e a Transformada Wavelet são métodos muito populares para o melhoramento desta relação.
- **Redução de dimensionalidade:** Quando a dimensionalidade da entrada é muito grande, é comum a utilização de métodos para a redução da dimensionalidade das variáveis de entrada. Estes métodos consistem em, a partir das variáveis de entrada originais, encontrar combinações entre elas que possam determinar novas variáveis de entrada e diminuir a quantidade total delas. O método mais comum deste tipo de extração de características é a Análise de Componentes Principais (PCA, do inglês *Principal Component Analysis*).

Outros métodos de extração de características podem ser encontrados na literatura, mas estes apresentados aqui já resolvem a grande maioria dos problemas que serão detalhados no curso. Caso seja necessário outro método, falaremos especificamente sobre ele.



Coordenadoria de
Educação Aberta e a Distância