


Aprendizado de Máquinas

Rodolpho Neves



Universidade Federal de Viçosa

Reitor

Demetrius David da Silva

Vice-Reitora

Rejane Nascentes



Diretor

Francisco de Assis de Carvalho Pinto

Campus Universitário, 36570-900, Viçosa/MG

Telefone: (31) 3612 1251

Layout: Ana Luísa Medeiros e Stéfany Peron

Editoração Eletrônica: Ana Luísa Medeiros

Edição de conteúdo e CopyDesk: João Batista Mota



Significado dos ícones da apostila

Para facilitar o seu estudo e a compreensão imediata do conteúdo apresentado, ao longo de todas as apostilas, você vai encontrar essas pequenas figuras ao lado do texto. Elas têm o objetivo de chamar a sua atenção para determinados trechos do conteúdo, com uma função específica, como apresentamos a seguir.



DESTAQUE: são definições, conceitos ou afirmações importantes às quais você deve estar atento.



GLOSSÁRIO: Informações pertinente ao texto, para situá-lo melhor sobre determinado termo, autor, entidade, fato ou época, que você pode desconhecer.

SAIBA MAIS: se você quiser complementar ou aprofundar o conteúdo apresentado na apostila, tem a opção de links na internet, onde pode obter vídeos, sites ou artigos relacionados ao tema.



PARA REFLETIR: vai fazer você relacionar um tópico a uma situação externa, em outro contexto



Exercícios Propostos: são momentos pra você colocar em prática o que foi aprendido



5. *Sistemas de Lógica Fuzzy (Nebulosa)*

O cérebro humano pode lidar facilmente com informações abstratas ou imprecisas, quando comparado à lógica matemática que funciona nos computadores. Por exemplo, é possível afirmar se uma pessoa é jovem ou idosa apenas olhando para ela, sem precisar saber exatamente a sua idade. Ou ainda, se for uma criança, é possível distinguir se ela é esta na fase bebê ou jovem. Não é realmente necessário saber a idade da pessoa para saber se é um bebê, um jovem, um adulto jovem ou idosa.

Quando criamos sistemas inteligentes, queremos que a máquina consiga fazer inferências a partir de informações com certo nível de nebulosidade. Embora os modelos de redes neurais artificiais trabalhem com informações precisas, no mundo real, essas informações podem ser fornecidas com imprecisões ou estão inseridas dentro de um contexto. O cérebro humano é capaz de contextualizar e processar informações difusas. Nesse caso, sistemas de inferência baseados em lógica fuzzy podem auxiliar a máquina a “pensar” um pouco mais parecido com o cérebro humano.

1.FUNDAMENTOS DA LÓGICA FUZZY

Quando dizemos que uma pessoa é alta ou baixa, não estamos definindo exatamente quanto é a altura dela. Entretanto, durante a comunicação de duas pessoas, elas vão entender se repassarem a informação dessa maneira: “Alice é baixa” ou “Emanoel é alto”. As alturas de Alice e Emanoel estão inseridas nessas frases de maneira vaga, sem serem expressas em número exatos.



O conceito fundamental da lógica nebulosa (do inglês *fuzzy logic*) tem origem no aumento de complexidade de contexto na informação, diminuindo sua exatidão e mantendo um nível de significância para que o cérebro humano, ou a máquina, seja capaz de fazer inferências precisas. Portanto, a lógica fuzzy representa o grau de verdade, e não a exatidão da informação.

Os computadores são construídos baseados na lógica tradicional, ou lógica booleana. Nela, os valores são definidos entre verdadeiro ou falso, de forma absoluta. A Figura 25 apresenta a definição de intervalos de temperatura de uma sala de escritório, descrita de acordo com a lógica booleana e com a lógica *fuzzy*. Na Figura 25(a), as definições de temperatura são rigidamente definidas, por exemplo: entre 10° e 15 °C é denominado “Frio”. Já na lógica *fuzzy*, Figura 25(b), a definição da temperatura para o mesmo intervalo pode ser “Muito frio” ou “Frio”, com um certo grau de verdade, dependendo de quem definiu os valores para estes intervalos. O mesmo pode acontecer no intervalo entre 25° e 30 °C, na qual para a lógica booleana é denominado “Muito quente” e na lógica fuzzy como “Quente” e “Muito quente”.




Figura 25 – Diferença entre definições de temperatura de acordo com a (a) lógica booleana e a (b) lógica fuzzy

2. VARIÁVEIS LINGÜÍSTICAS E FUNÇÕES DE PERTINÊNCIA

No exemplo apresentado na Figura 25(b), cada uma das definições para temperatura é denominada como um conjunto. Como todos os conjuntos têm certo grau de nebulosidade, eles podem ser nomeados conjuntos *fuzzy*. Podemos definir o conjunto *fuzzy* como $\text{Temp} = \{\text{"Muito frio", "Frio", "Confortável", "Quente", "Muito quente"}\}$. Cada elemento deste conjunto é representado matematicamente por uma função de pertinência $\mu_A(\text{Temp})$, na qual A é a variável linguística associada àquela função de pertinência da variável Temperatura. Por exemplo, a variável linguística "Frio" é definida por uma função de pertinência triangular com início em 10 $^{\circ}\text{C}$, centro em 15 $^{\circ}\text{C}$ e final em 20 $^{\circ}\text{C}$. Podemos defini-la como $\mu_{\text{Frio}}(\text{Temp}) = \text{triang}(10, 15, 20)$.

Em termo de notações, podemos definir:


- **Variável:** a variável que está sendo analisada (Temperatura ($^{\circ}\text{C}$)).
- **Universo de discurso:** o domínio que a variável está definida (Temperatura de 0° a 30 $^{\circ}\text{C}$).
- **Variáveis linguísticas:** definições linguísticas da variável ("Muito frio", "Frio", "Confortável", "Quente", "Muito quente").
- **Função de pertinência $\mu_A(X)$:** função que define a variável linguística no universo de discurso da variável. A variável linguística "Muito frio" é definida como trapezoidal e "Frio", como triangular. Existem outras funções mais comuns, como sigmoide, sino e gaussiana, mas pode ser qualquer função matemática convexa no domínio da variável.
- **Grau de pertinência:** valor da função de pertinência para um dado valor da variável (valor real de 0 a 1).

2.1. Notações e propriedades de conjuntos *crisp*s

A lógica fuzzy lida com um conjunto de números e variáveis denominado conjunto *crisp*. Ele é uma coleção de elementos que podem pertencer ou não a determinado conjunto, por exemplo, plantas reais e plantas artificiais. Os agrupamentos podem ser feitos com todas as plantas que são vivas e que excluem todas as plantas artificiais. Em termos de números, podemos definir: o conjunto de números ímpares no intervalo de 0 a 10 resulta em $A = \{1, 3, 5, 7, 9\}$ ou o conjunto de múltiplos de 3 de 0 a 10, $B = \{0, 3, 6, 9\}$.

Podemos manipular conjuntos *crisp* e fazer operações com eles, como:

- **União:** $A \cup B = \{x \mid x \in A \text{ OU } x \in B\} = \{0, 1, 3, 5, 6, 7, 9\}$
- **Interseção:** $A \cap B = \{x \mid x \in A \text{ E } x \in B\} = \{3, 9\}$
- **Complemento:** $\bar{A} = \{x \mid x \notin A, x \in X\} = \{0, 2, 4, 6, 8, 10\}$
- **Diferença:** $A - B = A \setminus B = \{x \mid x \in A \text{ E } x \notin B\} \Rightarrow A - (A \cap B) = \{1, 5, 7\}$



Os conjuntos crisp apresentam certas propriedades que podem ser úteis durante a manipulação de seus elementos, como:

- **Comutatividade:**
 - $A \cup B = B \cup A$
 - $A \cap B = B \cap A$
- **Associatividade:**
 - $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
 - $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
- **Distributividade:**
 - $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
 - $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
- **Idempotente:**
 - $A \cup A = A$
 - $A \cap A = A$
- **Transitividade:**
 - Se $A \subseteq B \subseteq C$ então $A \subseteq C$

- **Exemplo**

Um grupo de 4 pessoas está se mudando para a capital do estado onde vivem. Uma das premissas na hora da escolha da nova casa será o número mínimo de quartos que a casa deve ter. O grupo entrou em consenso que queriam uma casa grande e escolheram 10 casas para verificarem, antes de assinar o contrato. O universo de discurso da escolha será então o conjunto $\mathcal{U} = \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$. Durante as visitas, a cada uma das casas foram atribuídos valores de pertinência para as variáveis Conforto e Tamanho, descritas pelos conjuntos:

$$c = \{0,2; 0,5; 0,8; 1; 0,7; 0,3; 0; 0; 0; 0\}$$

e

$$t = \{0; 0; 0,2; 0,4; 0,6; 0,8; 1; 1; 1; 1\}$$

respectivamente.

A interseção entre os conjuntos Conforto e Tamanho é definida como:

$$c \cap t = \min(c, t) = \left\{ \frac{0}{1}; \frac{0}{2}; \frac{0,2}{3}; \frac{0,4}{4}; \frac{0,6}{5}; \frac{0,3}{6}; \frac{0}{7}; \frac{0}{8}; \frac{0}{9}; \frac{0}{10} \right\}$$

A interpretação deste conjunto é que a casa número 5 é a que melhor atende ao grupo, com o maior valor de pertinência: 0,6. Entretanto, não é tão boa assim, já que a pertinência está muito longe de 1. A segunda escolha seria a casa 4, com pertinência 0,4. Se a procura por casas no mercado local não estiver aquecida, talvez seja interessante que o grupo espere um pouco até que as ofertas melhorem e eles sejam plenamente atendidos (pertinência 1).

Caso eles renunciem a um dos critérios, a análise pode ser feita pela união de Conforto e Tamanho, dado por:

$$c \cup t = \max(c, t) = \left\{ \frac{0,2}{1}; \frac{0,5}{2}; \frac{0,8}{3}; \frac{1}{4}; \frac{0,7}{5}; \frac{0,8}{6}; \frac{1}{7}; \frac{1}{8}; \frac{1}{9}; \frac{1}{10} \right\}$$

Neste caso, a casa número 4 atende plenamente a um dos critérios, porque é confortável. As casas 7 a 10 também são satisfatórias, porque são grandes. Se a demanda no mercado de casas estiver alta, o grupo pode escolher uma destas 5 casas que estarão plenamente atendidos por um dos critérios.

3. MÉTODO DE INFERÊNCIA FUZZY

Modelos de aprendizado de máquina baseado em lógica *fuzzy* funcionam seguindo o processo apresentado na Figura 26. A entrada real *crisp* é repassada para o modelo baseado em um sistema de lógica *fuzzy*. O processamento da lógica *fuzzy* é feito a partir do grau de pertinência da entrada *crisp*, que será obtido no processo de fuzificação. Depois de fuzificada, a entrada passa pelo processo de inferência, no qual são identificadas as regras ativadas do conjunto de Base de regras e é formada a área agregada. A área agregada passa pelo processo de defuzificação para fornecer a saída *crisp*.




Figura 26 – Processo para realização da inferência fuzzy

3.1.Fuzificação

Equipamentos eletrônicos e computadores digitais foram desenvolvidos para operar com dados de conjuntos *crisp*. Essas máquinas são capazes de manipular e fazer operações entre conjuntos baseados na lógica booleana. A construção de máquinas inteligentes, com a aplicação de lógica *fuzzy*, requer que os conjuntos *crisp* sejam transformados em conjuntos *fuzzy*. Este processo é denominado fuzificação.



A fuzificação consiste em atribuir determinado nível de incerteza ao conjunto *crisp* para que a informação possa ser processada de maneira nebulosa, como no cérebro humano. Considere o conjunto *crisp* de temperatura apresentado na Figura 27(a), para temperatura “Quente”.

Podemos definir o conjunto *crisp* de “Quente” como:

$$C_{Quente}(Temp) = \{20,21,22,23,24,25\}$$

Todos os valores que pertencem ao conjunto $C_{Quente}(Temp)$ têm um grau de pertinência igual a 1, e grau de pertinência igual a 0, se não pertencem ao conjunto.




Figura 27 – Processo de fuzificação de um conjunto *crisp*

Feito a fuzificação do conjunto, podemos definir o conjunto *fuzzy* como:

$$\mu_{Quente}(\text{Temp}) = \left\{ \frac{0}{20}; \frac{0,2}{21}; \frac{0,4}{22}; \frac{0,6}{23}; \frac{0,8}{24}; \frac{1}{25}; \frac{0,8}{26}; \frac{0,6}{27}; \frac{0,4}{28}; \frac{0,2}{29}; \frac{0}{30} \right\}$$

na qual as razões significam que para 20 °C, a pertinência é 0; para 21 OC a pertinência é 0,2, e vai aumentando até ser 1 para 25 OC. E começa a diminuir até que a pertinência seja 0 para 30 OC. Todos os valores que estão fora deste conjunto recebem o grau de pertinência 0. Os conjuntos *fuzzy* podem ser manipulados, assim como os conjuntos *crisp*, e todas as propriedades dos conjuntos *crisp* podem ser aplicadas aqui.

Os conjuntos fuzzy podem representar qualquer tipo de variável por meio das variáveis linguísticas e das funções de pertinência. A fuzificação dessas variáveis pode ser feita de maneira manual/subjetiva, de acordo com a experiência ou intuição de quem está construindo os conjuntos *fuzzy* e de maneira automática, utilizando técnicas computacionais como clusterização, redes neurais artificiais e algoritmos genéticos.

Após fuzificar a entrada *crisp*, o conjunto *fuzzy* é repassado para a etapa de inferência *fuzzy*. Essa inferência acontece a partir de uma base de regras e a manipulação dos conjuntos fuzzy.

3.2. Base de regras para inferência fuzzy

A inferência *fuzzy* acontece a partir de um banco de regras que relaciona todas as variáveis linguísticas da entrada com as variáveis linguísticas da saída. O objetivo da construção da base de regras é descrever o comportamento do problema que está sendo modelado.

Suponha que você esteja construindo um sistema de inferência por lógica fuzzy para definir quanto pagar ao garçom a gorjeta em um restaurante. As variáveis de entrada serão a qualidade da comida e a qualidade de atendimento do garçom. A variável de saída será a quantidade da gorjeta que será paga.

As variáveis de entrar são definidas como:

$$\text{Comida} = \{\text{Normal}, \text{Ótima}\} \text{ e}$$

$$\text{Serviço} = \{\text{Ruim}, \text{Bom}, \text{Ótimo}\}$$

A variável de saída é definida como:

$$\text{Gorjeta} = \{\text{Pouca}, \text{Média}, \text{Alta}\}$$

A construção das regras do sistema de inferência baseado em lógica fuzzy devem ser do tipo:

SE premissa E premissa OU premissa ..., ENTÃO consequência

Portanto, para o problema da gorjeta, podemos criar as regras como:

SE Comida é Normal E Serviço é Ruim, ENTÃO Gorjeta é Pouca.

SE Comida é Normal E Serviço é Bom, ENTÃO Gorjeta é Média.

SE Comida é Ótima OU Serviço é Ótimo, ENTÃO Gorjeta é Alta.

A regra só é ativada se a pertinência de uma amostra de dentro do universo de discurso da variável for maior que zero. Uma vez ativada, a regra é levada em consideração para a construção do valor de saída do modelo. De posse das regras e dos conjuntos *fuzzy* que descrevem as entradas e as saídas, a lógica *fuzzy* já é capaz de sintetizar uma predição para uma determinada entrada que for repassada ao modelo.

3.3. Defuzificação

A interpretação dos conjuntos *fuzzy* funciona muito bem durante o processo de inferência. Entretanto, para que a informação seja extraída da lógica *fuzzy* e seja aplicada a algum problema, é necessário fazer a defuzificação do conjunto *fuzzy* em um conjunto *crisp* de saída.



O processo de defuzificação consiste em interpretar os graus de pertinência do conjunto *fuzzy* de saída em um valor *crisp*. O valor *crisp* de saída representa a predição feita pelo modelo baseado em lógica *fuzzy*, de acordo com as entradas repassadas ao algoritmo.

Existem diversos métodos de fazer a defuzificação e os mais utilizados são:

- **Método do bisetor (bisetor):** divide a área agregada por uma linha em duas áreas de mesmo valor. A posição da linha representa o valor *crisp* de saída.
- **Posição dos máximos:** o valor *crisp* de saída é dado pela posição dos máximos da área agregada. Podem ser escolhidos três posições: menor máximo (**SOM**), meio dos máximos (**MOM**) e maior máximo (**LOM**).
- **Centro de gravidade ou centro de área (centroid):** calcula a posição de centroide da área agregada e escolhe o valor *crisp* correspondente à posição. Matematicamente, o método de centro de área faz a média ponderada da posição pela pertinência de cada ponto.

Não é possível afirmar qual é o melhor método de defuzificação entre eles, porque depende do problema que está sendo resolvido. Mas deve-se observar que o método de centro de área é o que mais leva em consideração todos os pontos da área agregada. O exemplo na Figura 28 apresenta diferentes valores de defuzificação para cada um dos métodos apresentados. Os métodos do bisetor e de centro de área resultam em saídas mais próximas, mas ainda podem ser diferentes.




Figura 28 – Comparação dos métodos de defuzificação

Fonte: Extraído do documento de ajuda do Matlab

3.4. Metodologias de inferência

Modelos baseados em lógica *fuzzy* seguem diretrizes para interpretar as regras e os valores de grau de pertinência, associados a cada variável linguística do processo. Duas dessas diretrizes são mais comuns de serem abordadas: a inferência de Mamdani e a inferência de Takagi-Sugeno-Kang.

- **Método de Inferência Mamdani**

O método de inferência Mamdani foi desenvolvido para resolver problemas relacionados a controle de processos. A implicação pela inferência Mamdani é feita aplicando o operador

mínimo, para cada regra ativada, entre a pertinência resultante das premissas e a pertinência da consequência.

- **Exemplo:**

Voltando ao exemplo das regras para o problema da gorjeta ao garçom, vamos definir os conjuntos fuzzy das entradas e das saídas para que possamos aplicar o método de inferência Mamdani. As variáveis de entrada do problema da gorjeta são Comida e Serviço e a variável de saída é a Gorjeta. O universo de discurso das variáveis de entrada são notas de 0 a 10 e da saída é o percentual do valor da conta que será adicionado como gorjeta aos funcionários, de 5% a 15%. Os conjuntos *fuzzy* que definem as entradas e a saída pode ser visto na Figura 29. As entradas são definidas como funções de pertinência trapezoidais e triangulares, enquanto a saída é definida apenas por triangulares.




Figura 29 – Conjuntos *fuzzy* de entrada e saída do problema da gorjeta

As regras que relacionam as variáveis de entrada e saída foram definidas enquanto falávamos sobre a “Base de regras” do processo de inferência fuzzy. Elas são apresentadas de maneira gráfica na Figura 30, onde a primeira coluna representa a entrada Comida, a segunda, Serviço e a terceira, Gorjeta.

No processo de inferência, vamos atribuir aos operadores E e OU as operações mínimo e máximo, respectivamente. Ao operador, então, será atribuída a inferência Mamdani, que é interpretada como a operação mínimo. Assim, a pertinência de cada regra ativada será o mínimo entre as pertinências das premissas combinadas, com E e OU, e a pertinência da variável linguística da saída. Após a inferência, a área final será agregada de acordo com o operador máximo para que seja defuzificada por algum método de defuzificação.

Portanto, em uma noite de comemoração, um cliente do restaurante atribuiu as notas 5 e 4 para Comida e Serviço, pois o casal estava com expectativas muito altas para a noite. De acordo com o sistema baseado em lógica fuzzy que desenvolvemos até o momento, qual será a gorjeta equivalente às notas atribuídas pelos clientes?




Figura 30 – Representação da base de regras do problema da gorjeta em forma gráfica

A Figura 31 ilustra como as regras são ativadas e como a área agregada para a defuzzificação é construída. Ao aplicar a nota 5 para Comida, as pertinências calculadas foram $\mu_{\text{Normal}}(5) = 1$, $\mu_{\text{Ótima}}(5) = 0$. Para a variável Serviço, as pertinências calculadas foram $\mu_{\text{Ruim}}(4) = 0,5$, $\mu_{\text{Bom}}(4) = 0,5$ e $\mu_{\text{Ótimo}}(4) = 0$.

Como os conectores das premissas das Regras 1 e 2 são o E, a operação que será feita entre os valores de pertinências das premissas é a operação mínimo. Então, na Regra 1, $\min(\mu_{\text{Normal}}(5), \mu_{\text{Ruim}}(4)) = 0,5$ e na Regra 2, $\min(\mu_{\text{Normal}}(5), \mu_{\text{Bom}}(4)) = 0,5$. Já na Regra 3, como o conector das premissas é o OU, o operador desta regra é a operação máximo, resultando em $\max(\mu_{\text{Ótima}}(5), \mu_{\text{Ótimo}}(4)) = 0$. Assim, as Regras 1 e 2 foram ativadas, mas a Regra 3 não foi ativada, porque resultaram em valores de pertinência 0,5, 0,5 e 0, respectivamente.

A definição da área de cada regra ativada é feita pelo método de inferência Mamdani, dada pelo operador mínimo entre o valor de pertinência das premissas e a função de pertinência de saída. Então, aplicando o operador mínimo, a área de cada regra é dada pela última coluna da Figura 31.




Figura 31 – Ativação das regras e área agregada de saída do problema da gorjeta com as notas Comida = 5 e Serviço = 4

Ao realizar a soma das áreas das regras ativadas, aplicando o operador máximo de todas as áreas, a área agregada é encontrada. O resultado da inferência fuzzy será calculado pela defuzzificação desta área agregada. No caso deste exemplo, foi utilizado o método de centro de área (centroid), resultando em uma gorjeta de 9,4%.

Qual seria o resultado para as notas Comida = 8 e Serviço = 5? Como seriam os resultados com os outros métodos de defuzzificação?

- **Método de Inferência Takagi-Sugeno-Kang**

O método de inferência de Takagi-Sugeno-Kang (TS) utiliza combinações lineares das entradas, ou, até mesmo, funções complexas. De maneira geral, as funções de pertinência da variável de saída que compõem as regras do método de inferência TS são do tipo

$$\text{SE } x_1 \text{ é } A_1 \text{ E } x_2 \text{ é } B_1, \text{ ENTÃO } y_1 = f(x_1, x_2)$$

na qual x_1 e x_2 são os valores *crisp* de entrada do problema e $y_1 = f(x_1, x_2)$ é o polinômio do método de inferência TS, que pode ser um polinômio de ordem zero, ordem um ou ordem n.

As funções de pertinência do polinômio de ordem zero são representadas por impulso unitários (*singleton*), posicionado em um valor fixo (constante) e pertinência 1. Se a função $f(x_1, x_2)$ for um polinômio de ordem um, a função será do tipo $f(x_1, x_2) = ax_1 + bx_2 + c$, na qual a e b são os pesos para cada entrada e c é uma constante, que também pode ser ajustada pelo desenvolvedor do sistema de lógica fuzzy. Depois de calculada a contribuição de cada regra, a saída é calculada de acordo com a soma das contribuições, ponderadas pela pertinência do conjunto de premissas. Em um sistema fuzzy de inferência TS com duas regras, a saída y é dada por

$$y = \frac{\mu_1 * y_1 + \mu_2 * y_2}{\mu_1 + \mu_2}$$

na qual y_1 e y_2 são as contribuições de cada regra e μ_1 e μ_2 são as pertinências do conjunto de premissas da regra 1 e da regra 2, respectivamente.



O método de inferência Takagi-Sugeno-Kang (muitas vezes referenciado apenas como Takagi-Sugeno, ou ainda, Sugeno) é mais eficiente em termos de custo computacional por calcular apenas uma média ponderada de alguns dados de saída, ao invés de calcular o centro da área agregada durante a inferência Mamdani.

- **Exemplo:**

Voltando ao exemplo da gorjeta ao garçom, vamos aplicar o método de inferência Takagi-Sugeno-Kang. As variáveis de entrada do problema da gorjeta e as funções de pertinência das entradas vão continuar as mesmas. As regras que vamos utilizar no método de inferência TS serão dadas por:

SE Comida é Normal E Serviço é Ruim, ENTÃO Gorjeta é $y_1 = 0,1 * Comida + 0,1 * Serviço + 5$

SE Comida é Normal E Serviço é Bom, ENTÃO Gorjeta é $y_2 = 0,25 * Comida + 0,25 * Serviço + 5$.

SE Comida é Ótima OU Serviço é Ótimo, ENTÃO Gorjeta é $y_3 = 0,5 * Comida + 0,5 * Serviço + 5$.

No conjunto de notas Comida = 6,5 e Serviço = 5, a contribuição de cada regra é:

$$\begin{cases} y_1 = 0,1 * 6,5 + 0,1 * 5 + 5 = 6,15 \\ y_2 = 0,25 * 6,5 + 0,25 * 5 + 5 = 7,875 \\ y_3 = 0,5 * 6,5 + 0,5 * 5 + 5 = 10,75 \end{cases}$$

Considerando as funções de pertinência que fuzificam as entradas, apresentada na Figura 31, as pertinências das regras para os valores de entrada Comida = 5 e Serviço = 4 são:

$$\begin{cases} \mu_1 = \min(\mu_{\text{Normal}}(\text{Comida}), \mu_{\text{Ruim}}(\text{Serviço})) = \min(0,5; 0) = 0 \\ \mu_2 = \min(\mu_{\text{Normal}}(\text{Comida}), \mu_{\text{Bom}}(\text{Serviço})) = \min(0,5; 1) = 0,5 \\ \mu_3 = \max(\mu_{\text{Ótima}}(\text{Comida}), \mu_{\text{Ótimo}}(\text{Serviço})) = \max(0,5; 0,5) = 0,5 \end{cases}$$

Então, a Gorjeta do problema, utilizando o método de inferência Takagi-Sugeno-Kang, é:

$$y = \frac{\mu_1 * y_1 + \mu_2 * y_2 + \mu_3 * y_3}{\mu_1 + \mu_2 + \mu_3} = \frac{0 * 6,15 + 0,5 * 7,875 + 0,5 * 10,75}{0,5 + 0,5 + 0} = 9,3125\%.$$

A Gorjeta paga utilizando o método de inferência TS é diferente daquela do método de inferência Mamdani. Para que sejam respectivas, é necessário alterar os parâmetros dos polinômios das regras do sistema TS ou as funções de pertinência do método de inferência Mamdani.

A dificuldade de se utilizar o sistema de inteligência artificial baseado em lógica fuzzy está no ajuste dos parâmetros. Como na maior parte das vezes utilizamos apenas a experiência de um especialista para o ajuste das regras, universo de discurso e funções de pertinência, este processo se torna custoso e enviesado. E, ainda, dependendo de quem desenvolve o modelo, o algoritmo pode não obter resultados tão precisos quanto necessários. Uma forma de resolver

esses empecilhos da busca paramétrica nos sistemas baseados em lógica fuzzy é utilizar uma arquitetura que reúne a capacidade de interpretação de informações nebulosas com a facilidade de ajuste de redes neurais artificiais e o algoritmo de backpropagation, denominada sistema de inferência neuro-fuzzy adaptativo.

3.4. Sistema de Inferência Neuro-fuzzy

A combinação entre as redes neurais artificiais e a lógica *fuzzy* resulta em um sistema de inferência *neuro-fuzzy* adaptativo (do inglês *adaptive neuro-fuzzy inference system*, ANFIS). O ANFIS é uma topologia poderosa e eficiente de máquina inteligente, que modela sistemas reais com determinados níveis de incerteza, criando um sistema de inferência capaz de interpretar informações de maneira similar ao cérebro humano.

O ajuste dos parâmetros das funções de pertinência é feito de maneira automática e interativa durante a fase de treinamento do ANFIS. Pode-se dizer que o ANFIS é uma topologia de sistema de inferência *fuzzy* que utiliza um algoritmo de aprendizagem híbrido para diminuir o erro de predição do modelo. Ainda, este tipo de rede *feed-forward* tem múltiplas camadas: algumas são adaptativas e conecta as outras sem a presença de pesos entre elas. Cada camada do ANFIS apresenta uma função diferente e os parâmetros dessas camadas são ajustadas por meio de uma regra de ajuste, como no algoritmo *backpropagation*. Entretanto, o algoritmo de aprendizagem híbrido acelera a convergência do ANFIS e auxilia no processo de evitar mínimos locais durante a otimização.

4. IMPLEMENTAÇÃO DE REDES NEURO-FUZZY

Como na rede *perceptron* multicamadas, o ANFIS é uma rede que utiliza o algoritmo de treinamento supervisionado. Vamos expor o algoritmo de um ANFIS por meio de um exemplo.

Considere um sistema ANFIS com duas entradas x e y e uma saída z . Considere também que ele tenha duas regras *Se – Então*, que são:

- **Regra 1:** Se x é A_1 E y é B_1 Então $z_1 = p_1x + q_1y + r_1$
- **Regra 2:** Se x é A_2 E y é B_2 Então $z_2 = p_2x + q_2y + r_2$

na qual A_1 , A_2 , B_1 e B_2 são funções de pertinência das entradas x e y , respectivamente. Os coeficientes p_1 , p_2 , q_1 , q_2 , r_1 e r_2 são parâmetros lineares do modelo de inferência fuzzy Takagi-Sugeno-Kang. A Figura 32 apresenta as premissas do ANFIS e as funções de pertinência que formulam as regras 1 e 2.




Figura 32 – Premissas do ANFIS para as entradas x e y

A arquitetura do ANFIS para este caso pode ser considerada uma rede neural composta por

5 camadas (Figura 33). A primeira e a quarta camadas são adaptáveis, aquelas que têm seus parâmetros alterados durante a fase de treinamento da rede. As outras camadas são fixas, ou seja, não têm parâmetros para ajuste. As funções das camadas são:

- **1ª camada: fuzificação das entradas crisps** - nesta camada ocorre a transformação de um valor real do universo de discurso para um valor fuzzy, que pertence às funções de pertinência. Os parâmetros que podem ser ajustados nesta camada são os das funções de pertinência: tipo, posição, início e fim.
- **2ª camada: cálculo do peso da regra (força de disparo)** - nesta camada ocorre o produto dos graus de pertinência para cada premissa da regra. Nesse caso específico, $w_1 = \mu_{A1}(x) \cdot \mu_{B1}(x)$ e $w_2 = \mu_{A2}(x) \cdot \mu_{B2}(x)$. Não há ajuste de parâmetro nessa camada.
- **3ª camada: normalização dos pesos das regras** - nesta etapa, o peso de cada regra é normalizado em relação à soma dos pesos de todas as regras. Nesse caso específico, a normalização acontece por:

$$\bar{w}_i = \frac{w_i}{w_1 + w_2}$$




Figura 33 – Topologia do ANFIS para o exemplo com duas entradas e uma saída

- **4ª camada: inferência pelo método Takagi-Sugeno-Kang** - as entradas x e y são repassadas para esta camada e são calculados os consequentes das regras z_1 e z_2 . Junto ao peso da regra normalizado, a saída desta camada é a contribuição de cada regra vai fazer na saída do modelo. Nesta etapa são ajustados os parâmetros dos consequentes que, neste caso, são os coeficientes lineares p_1 , p_2 , q_1 , q_2 , r_1 e r_2 .
- **5ª camada: soma da contribuição de cada regra** - nesta camada ocorre a soma das contribuições de cada regra ativada do ANFIS. Como já houve a normalização dos pesos das regras na 3ª camada, a saída desta é dada pela soma simples dos termos. Não há ajuste de parâmetros nesta camada. Por isso, a saída desta camada, que já é a saída *crisp* do modelo, é dada por:

$$z = \bar{w}_1 z_1 + \bar{w}_2 z_2$$



Com a topologia do ANFIS definida, podemos aplicar um algoritmo de aprendizagem híbrido para otimizar os parâmetros e reduzir o erro de predição. O algoritmo de treinamento híbrido é um processo de duas etapas que ajusta os parâmetros da 1ª e da 4ª camada, garantindo uma rápida convergência e evitando cair em mínimos locais da função otimizada.

Na primeira etapa do treinamento, fase de *forward*, os parâmetros da 1ª camada são fixados e os coeficientes lineares (parâmetros consequentes) da 4ª camada são ajustados pelo método do estimador de mínimos quadrados.

Na segunda etapa do treinamento, fase de *backward*, os parâmetros da 4ª camada são fixados e os das funções de pertinência (parâmetros das premissas) são ajustados pelo método do gradiente descendente. A saída é gerada a partir da alteração dos parâmetros consequentes e é calculado o erro de inferência do modelo. Tal erro é utilizado no método do gradiente descendente para fazer o ajuste dos parâmetros das premissas.



Coordenadoria de
Educação Aberta e a Distância