


*Inteligência Artificial
e Computacional*

ELT574

Aprendizado de Máquinas


Adaline e a Regra Delta

Conteudista: Rodolpho Neves




Otimização de parâmetros do perceptron

- Limitação de um perceptron
 - Ajuste não é feito de maneira ótima
 - Converge para qualquer parâmetro que solucione a classificação
 - Solução depende do ponto de inicialização dos parâmetros
- Mudar a forma de calcular o erro
 - Próprio valor da inferência
- Função de ativação recebe entrada mais próxima da saída




Adaptive Linear Neuron (Adaline)



Estrutura de um Adaline.

- Regra Delta
- Mínimo erro médio quadrado
- *Least mean square error* (LMS)
- Gradiente descendente



Cálculo do gradiente descendente (LMS)

- Cálculo do erro:

$$erro = d - u$$

- LMS:

$$E(W) = \frac{1}{2} \sum_{k=1}^p (d^{(k)} - u)^2 = \frac{1}{2} \sum_{k=1}^p (d^{(k)} - X^{(k)}W)^2$$

- Objetivo:


- Minimizar $E(W)$
- Ajustando os valores de W

- Gradiente do erro quadrático médio:


$$\nabla E(W) = \frac{\partial E(W)}{\partial W} = - \sum_{k=1}^p (d^{(k)} - u)X^{(k)}$$

- Resultando no ajuste dos pesos:

$$\Delta W = -\eta \nabla E(W) = \eta \sum_{k=1}^p (d^{(k)} - u)X^{(k)} \Rightarrow W^{atual} = W^{anterior} + \eta \sum_{k=1}^p (d^{(k)} - u)X^{(k)}$$




Comportamento e convergência do $E(W)$




Erro médio quadrático para cada ajuste dos parâmetros do Adaline pela Regra Delta.

$$EQM(W) = \frac{1}{p} \sum_{k=1}^p (d^{(k)} - u)^2$$



Separação das amostras linearmente separáveis com Adaline.

$$|EQM(W^{atual}) - EQM(W^{anterior})| \leq \varepsilon$$




Algoritmo de treinamento do Adaline

Início do treinamento – Adaline (com regra Delta):


1. Carregar o conjunto de treinamento para a matriz X com a entrada do limiar -1 ;
2. Carregar o conjunto de saídas desejadas para o vetor d ;
3. Atribuir valores aleatórios normalizados aos pesos sinápticos W (com o w_0);
4. Escolher o valor da taxa de aprendizado η e para o limiar de precisão ε ;
5. Determine o número máximo de épocas de treinamento $epoca_{max}$;
6. Iniciar o contador de épocas do treinamento ($epoca = 0$);
7. Faça até que $|EQM(W^{atual}) - EQM(W^{anterior})| \leq \varepsilon$:
 1. Faça $EQM(W^{anterior}) = EQM(W^{atual})$;
 2. Faça $EQM(W^{atual}) = 0$;
 3. Para cada amostra de treinamento $\{X^{(k)}, d^{(k)}\}$, faça:
 1. $u = X^{(k)}W$;
 2. $EQM(W^{atual}) = EQM(W^{atual}) + (d^{(k)} - u)^2$;
 3. $W^{atual} = W^{anterior} + \eta(d^{(k)} - u)X^{(k)}$;
 4. Faça $EQM(W^{atual}) = EQM(W^{atual}) / p$;
 5. Faça $epoca = epoca + 1$;
 6. Se $epoca > epoca_{max}$, pare o treinamento.

Fim



Considerações finais

- Adaptive linear neuron
 - Problemas de classificação linearmente separáveis
 - Aproximador de função linear
- Não é capaz:
 - Problemas de classificação não linearmente separável
 - Aproximar funções não lineares
- Perceptron multicamadas (PMC)



*Inteligência Artificial
e Computacional*

ELT574

Aprendizado de Máquinas


Conteudista:

Rodolpho Neves

rodolpho.neves@ufv.br

UFV
Universidade Federal de Viçosa

cead_{UFV}
Coordenadoria de
Educação Aberta e a Distância



Realização

UFV

Universidade Federal de Viçosa

