


*Inteligência Artificial
e Computacional*

ELT574

Aprendizado de Máquinas


Aspectos sobre treinamento
de redes neurais artificiais
e outros modelos

Conteudista: Rodolpho Neves




Aspectos gerais sobre o treinamento de modelos

- Cuidado na preparação e execução do treinamento
 - Divisão do banco de dados
 - Capacidade de generalização
 - Desempenho do modelo ajustado
- Interpretabilidade do algoritmo de aprendizado de máquinas
- Problemas de regressão e de classificação
 - Influência na estrutura da RNA
 - Número de neurônios
 - Funções de ativação
 - Indicador de desempenho




Banco de dados do problema


- Quantidade grande de exemplos
 - Principalmente se for um problema multiclases
 - Identificar dados significativos
 - Balanceamento entre classes
- Divisão do banco de dados em conjunto de treinamento e de teste
 - 70% a 90% para treinamento
 - 30% a 10% para teste
 - Seleção aleatória dos dados
 - Seleção sistemática
 - Validação cruzada de k-partições (*k-fold cross-validation*)



Validação cruzada *k-fold*


- Amostras do banco de dados
- Conjunto de treinamento
- Conjunto de teste







Interpretação de uma PMC

- Redes PMC com uma camada escondida
 - Resolvem muitos problemas não lineares




- Playground do TensorFlow
 - Ambiente educacional de construção de redes perceptron multicamadas






Underfitting e overfitting


- Underfitting
- Overfitting
- Boa generalização




Problema de Classificação




Problema de Regressão




Características do erro quadrático médio (EQM) para cada caso



Topologia da curva de EQM




Topografia de erro com mínimo local e mínimo global




Arquitetura típica para PMC de regressão

Hiperparâmetro	Valores típicos
Neurônios de entrada	Um por entrada
Camadas ocultas	Depende do problema (1 a 5)
Neurônios por camada	Depende do problema (10 a 100)
Função de ativação das camadas ocultas	ReLU
Neurônios de saída	Um por dimensão de predição
Função de ativação da camada de saída	Linear, ReLU (se saídas positivas) ou logística/tanh (saídas limitadas)
Função de desempenho	EQM ou EMA (ou Huber Loss)




$$y = f(x) = \begin{cases} x, & \text{se } x > 0 \\ 0, & \text{se } x \leq 0 \end{cases}$$

ReLU - <https://medium.com/>




Arquitetura típica para PMC de classificação

Hiperparâmetro	Classificação binária	Classificação binária múltipla	Classificação multiclasse
Neurônios de entrada	Um por entrada		
Camadas ocultas	Depende do problema (1 a 5)		
Neurônios por camada	Depende do problema (10 a 100)		
Função de ativação das camadas ocultas	ReLU		
Neurônios de saída	1	1 por rótulo	1 por classe
Função de ativação da camada de saída	Logística	Logística	Softmax
Função de desempenho	Cross Entropy (Log loss)		



Considerações finais

- Treinamento exige estudo do problema
- Seleção de características como entradas significantes
- Definição do problema
- Escolha da estrutura do modelo
- Treinamento com boas amostras
- Evitar underfitting e overfitting
- Medir o desempenho do modelo



*Inteligência Artificial
e Computacional*

ELT574

Aprendizado de Máquinas


Conteudista:

Rodolpho Neves

rodolpho.neves@ufv.br

UFV
Universidade Federal de Viçosa

cead_{UFV}
Coordenadoria de
Educação Aberta e a Distância



Realização

UFV

Universidade Federal de Viçosa

