


Aprendizado de Máquinas

Rodolpho Neves



1 Aprendizado não supervisionado

O aprendizado não supervisionado é uma área da inteligência artificial que se concentra na análise de dados que não possuem rótulos ou saídas conhecidas. Nesse tipo de aprendizado, o modelo não recebe exemplos de entrada e saída como no aprendizado supervisionado. Em vez disso, ele explora a estrutura subjacente dos dados para identificar padrões ou agrupamentos, sem qualquer orientação sobre o que deve ser considerado um “resultado correto”.

Uma analogia comum para o aprendizado não supervisionado é imaginar que ele atua como um explorador ou um investigador, tentando desvendar as “histórias” contidas nos dados, independentemente de informações prévias. Por exemplo, em um conjunto de dados contendo informações sobre clientes, o aprendizado não supervisionado pode identificar grupos de clientes com comportamentos ou características semelhantes, ajudando a entender segmentos de mercado, padrões de consumo ou características de diferentes perfis.

O principal objetivo do aprendizado não supervisionado é a descoberta de conhecimento. Ele permite aos cientistas de dados e pesquisadores identificar estruturas e padrões complexos que podem ser utilizados em fases posteriores da análise de dados [1–5]. Esses padrões ou grupos descobertos servem como uma base valiosa para:

- Tomada de decisões estratégicas, como segmentação de clientes para campanhas de marketing;
- Identificação de tendências e comportamentos emergentes;
- Auxílio em sistemas de recomendação, personalização e descoberta de produtos.

Além disso, o aprendizado não supervisionado é frequentemente utilizado para reduzir a dimensionalidade dos dados, simplificando modelos e melhorando a interpretação de grandes conjuntos de dados.

1.1 Diferenças entre aprendizado supervisionado e não supervisionado

O aprendizado supervisionado e o aprendizado não supervisionado possuem abordagens e finalidades distintas. No aprendizado supervisionado, os modelos são treinados com dados rotulados – ou seja, dados onde as respostas desejadas (rótulos) são conhecidas. Isso permite que o modelo aprenda a associar entradas específicas com saídas específicas, permitindo fazer previsões ou classificações para novos dados com base nos padrões aprendidos.

Por outro lado, o aprendizado não supervisionado lida com dados não rotulados. Em vez de associar entradas a respostas, ele tenta identificar padrões ou agrupamentos sem saber antecipadamente o que representam. A Tabela 1 resume as principais diferenças.


Tabela 1: Comparação entre aprendizado supervisionado e não supervisionado.

Característica	Aprendizado supervisionado	Aprendizado não supervisionado
Dados	Dados rotulados	Dados não rotulados
Objetivo	Predição de rótulos	Descoberta de padrões
Exemplo de aplicação	Classificação de e-mails (spam/não spam)	Segmentação de clientes
Exemplo de algoritmo	Regressão linear, árvores de decisão	K-means, análise de componentes principais (PCA)

O aprendizado supervisionado é mais apropriado para problemas onde há uma quantidade significativa de dados rotulados, enquanto o aprendizado não supervisionado é ideal para cenários em que os dados são abundantes, mas os rótulos são escassos ou inexistentes.

1.2 Aplicações do Aprendizado não supervisionado

O aprendizado não supervisionado é amplamente utilizado em diversas áreas, principalmente onde é necessário explorar grandes quantidades de dados e descobrir padrões desconhecidos. Algumas das



aplicações mais comuns incluem:

Segmentação de mercado: O aprendizado não supervisionado é especialmente útil para segmentar clientes em grupos com base em características ou comportamentos similares. Essa técnica é muito utilizada em marketing para identificar diferentes segmentos e criar campanhas personalizadas. Ao agrupar clientes com base em fatores como histórico de compras, localização e preferências de produto, empresas conseguem realizar campanhas mais eficientes e aumentar a satisfação dos clientes.

Análise de anomalias: Identificar padrões anômalos é crucial em áreas como finanças e segurança. O aprendizado não supervisionado pode detectar comportamentos atípicos ou fora do comum, o que pode indicar fraudes, atividades suspeitas ou falhas. Por exemplo, em sistemas bancários, o aprendizado não supervisionado pode detectar transações incomuns que possam sinalizar uma tentativa de fraude.

Reconhecimento de padrões em imagens: No processamento de imagens, algoritmos não supervisionados podem agrupar pixels ou regiões de uma imagem com características semelhantes. Esse tipo de análise é útil para segmentação de imagens, onde áreas distintas (como céu, água, vegetação) são separadas automaticamente. Em sistemas de visão computacional, essa técnica é aplicada na detecção de objetos, reconhecimento facial e segmentação médica.

Redução de dimensionalidade: Em cenários com conjuntos de dados complexos e de alta dimensão, como análise de dados genômicos ou séries temporais de sensores, técnicas de redução de dimensionalidade, como a Análise de Componentes Principais (PCA), permitem simplificar os dados sem perder informações críticas. Isso facilita a visualização e interpretação dos dados, além de ajudar a diminuir o custo computacional em modelos subsequentes.

O aprendizado não supervisionado oferece, portanto, uma poderosa ferramenta para entender dados complexos, identificar padrões ocultos e ajudar na construção de soluções personalizadas para problemas reais, onde a necessidade de rotulagem manual pode ser inviável ou excessivamente onerosa.

2 Algoritmo de agrupamento K-means

O K-means é um dos algoritmos de agrupamento mais utilizados e estudados em aprendizado não supervisionado devido à sua simplicidade e eficiência em dados de alta dimensionalidade [3, 6]. Seu objetivo é dividir um conjunto de dados em K clusters, minimizando a variabilidade dentro de cada cluster e maximizando a separação entre os clusters.


2.1 Histórico do algoritmo K-means

O algoritmo K-means é um dos métodos mais antigos e amplamente utilizados para a tarefa de agrupamento (clustering) em aprendizado de máquina. Ele foi inicialmente introduzido por Hugo Steinhaus em 1956, em um contexto matemático de particionamento de dados, e depois formalizado como algoritmo por Stuart Lloyd em 1957 enquanto trabalhava na Bell Labs para compressão de dados [1]. O termo “K-means” só foi popularizado posteriormente por James MacQueen, em 1967, que expandiu o conceito e abordou questões de aplicações práticas e variações do método [7].

A ideia central do K-means tem raízes na análise matemática de particionamento de dados. O objetivo é minimizar a soma dos quadrados das distâncias entre os pontos de um cluster e seu respectivo centroide (ou média do cluster). Este problema é matematicamente formulado como uma solução aproximada para a minimização de variância dentro de grupos, um conceito já estudado na estatística [7].

Stuart Lloyd foi o primeiro a propor uma versão iterativa do algoritmo que é usada até hoje:

- Inicialização dos centroides;
- Atribuição dos pontos aos centroides mais próximos;
- Reajuste dos centroides como a média dos pontos atribuídos.



Embora o trabalho de Lloyd tenha sido uma inovação, ele foi inicialmente limitado ao contexto de compressão de sinais, em particular na quantização vetorial [1].

James MacQueen contribuiu significativamente para tornar o algoritmo mais conhecido, conectando-o com áreas como economia e biologia. Seu trabalho apresentou o K-means como um método geral de agrupamento. Durante as décadas de 1970 e 1980, variações do K-means surgiram para lidar com limitações como a sensibilidade aos valores iniciais dos centroides e a necessidade de pré-definir K , o número de clusters. Uma dessas variações foi o K-means++, introduzido por Arthur e Vassilvitskii em 2006, que melhora a inicialização dos centroides para reduzir os problemas de convergência local [6].

Hoje, o K-means é amplamente utilizado em diversas áreas, incluindo:

- Visão computacional, para segmentação de imagens;
- Marketing, para segmentação de clientes;
- Processamento de linguagem natural, para agrupamento de documentos.

2.2 Noções de similaridade e distância

O agrupamento (ou clustering) é uma técnica fundamental no aprendizado não supervisionado, que visa organizar um conjunto de dados em grupos, chamados de clusters. A ideia central do clustering é que os elementos de um mesmo grupo devem ser mais semelhantes entre si do que aos elementos de outros grupos, permitindo, assim, a identificação de padrões ou estruturas subjacentes nos dados.

Para avaliar a similaridade entre elementos, são utilizadas diversas métricas de distância. Essas métricas são essenciais para determinar o quão “próximos” ou “distantes” estão os pontos uns dos outros no espaço dos dados, sendo a escolha da métrica crucial para o sucesso do agrupamento. Abaixo, listamos algumas das métricas mais comuns:

- Distância Euclidiana: A distância euclidiana é a medida direta entre dois pontos em um espaço n -dimensional. É a métrica mais comum e intuitiva, calculada pela fórmula:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (1)$$

Onde x_i e y_i são vetores n -dimensionais. A distância euclidiana é adequada para dados com dimensões equivalentes e quando a proximidade linear dos pontos é importante.

- Distância de Manhattan: Também conhecida como distância de bloco, é a soma das distâncias absolutas em cada dimensão. A fórmula é:

$$d(x, y) = \sum_{i=1}^n |x_i - y_i| \quad (2)$$

Essa métrica é útil quando queremos enfatizar diferenças absolutas entre variáveis ou quando os dados possuem características mais “retangulares”, como no caso de dados de movimento em grades. A Figura 1 apresenta uma comparação entre a Distância Euclidiana e a Distância de Manhattan [8].

- Distância de Cosseno: A distância de cosseno mede o ângulo entre dois vetores, sendo útil para dados vetoriais em que a direção dos dados é mais importante do que sua magnitude, como em análise de texto. A fórmula da similaridade do cosseno é:

$$\text{similaridade}(x, y) = \frac{x \cdot y}{\|x\| \|y\|} \quad (3)$$

Onde $x \cdot y$ representa o produto escalar entre os vetores x e y . A similaridade de cosseno varia entre -1 e +1, onde +1 significa vetores perfeitamente alinhados e -1 significa vetores opostos.

A escolha da métrica de distância depende do tipo de dados e do problema específico. Em alguns casos, é necessário experimentar diferentes métricas para encontrar a mais adequada ao conjunto de dados e ao problema em questão.





Figura 1: Exemplo de dados sem rótulo e agrupados pelo algoritmo K-means.



Fonte: Adaptado de Terfrüchte and Frank [8].

2.3 Descrição do algoritmo

O algoritmo K-means pode ser dividido em cinco etapas principais:

1. Escolha de K : Inicialmente, o número de clusters, K , é definido. Esta escolha pode influenciar diretamente a qualidade do agrupamento e, muitas vezes, requer experimentação para encontrar o valor ideal. Aqui, é possível aplicar diferentes métodos, como o cotovelo e o coeficiente de silhueta, para ajudar a determinar o valor mais adequado de K (ver Seção 2.4).
2. Inicialização dos centroides: São selecionados K pontos iniciais, chamados de centroides, que representam o centro de cada cluster. Existem várias maneiras de selecionar os centroides iniciais:
 - Aleatoriamente: Escolhe K pontos aleatórios no conjunto de dados.
 - K-means++: Uma técnica mais sofisticada para escolher os centroides iniciais, garantindo uma maior separação entre os centroides e, geralmente, resultando em uma convergência mais rápida e melhor agrupamento (ver Seção 2.3.1).
3. Atribuição de Pontos: Cada ponto de dado é atribuído ao centroide mais próximo, formando clusters iniciais. A proximidade é geralmente medida pela distância euclidiana entre o ponto e os centroides.
4. Recálculo dos centroides: Após a atribuição dos pontos aos clusters, os novos centroides são calculados como a média dos pontos em cada cluster. Este passo é essencial para centralizar os clusters ao redor dos dados associados.
5. Iteração: Os passos de atribuição de pontos e recálculo dos centroides são repetidos até que ocorra um dos seguintes critérios de parada:
 - Convergência: Os centroides não mudam mais de posição, indicando que o agrupamento alcançou uma solução estável.
 - Número máximo de iterações: O processo é interrompido após um número pré-definido de iterações, útil para garantir que o algoritmo não demore excessivamente em casos onde a convergência é difícil de alcançar.

O K-means é um algoritmo iterativo e seu objetivo final é minimizar a soma das distâncias ao quadrado entre cada ponto e o centroide de seu cluster. Isso significa que o K-means está tentando criar clusters compactos e bem separados.

A Figura 2 apresenta um exemplo de como os dados são inicializados e como o algoritmo agrupa todos as amostras de treinamento. No caso da Figura 2b, foram inicializados três grupos no algoritmo para que fossem posicionados da melhor forma.





Figura 2: Exemplo de dados sem rótulo e agrupados pelo algoritmo K-means.



Fonte: Adaptado de Raschka et al. [4].

2.3.1 K-means++

O sorteio dos centroides iniciais para o ajuste do algoritmo K-means pode resultar em um posicionamento final sub-ótimo da solução. Uma forma de tentar evitar este sorteio sub-ótimo é utilizando o posicionamento inicial dos K centroides baseados no conjunto de dados do problema. Depois de realizado o sorteio dos K centroides iniciais, o algoritmo do K-means continua normalmente, conforme mencionado na Seção 2.3.

Os passos de inicialização dos K centroides pelo K-means++ são:

1. Seleção do Primeiro Centroide: Escolhe-se aleatoriamente o primeiro centroide a partir do conjunto de pontos de dados.
2. Cálculo das Distâncias: Para cada ponto do conjunto, calcula-se a distância ao centroide mais próximo, entre os centroides já selecionados. Essa distância é usada como um peso que indica a importância de cada ponto na próxima seleção e também pode ser interpretada como a probabilidade deste ponto ser escolhido.
3. Seleção Ponderada do Próximo Centroide: O próximo centroide é escolhido de maneira probabilística, onde a chance de um ponto ser selecionado é proporcional à sua distância ao centroide mais próximo já escolhido. Assim, os pontos mais distantes dos centroides anteriores têm maior probabilidade de serem selecionados como o próximo centroide.
4. Iteração: Repete-se o processo dos passos 2 e 3 até que sejam escolhidos K centroides.

2.4 Avaliação de resultados de agrupamento

Como o aprendizado não supervisionado não possui rótulos, a avaliação da qualidade de um agrupamento é um processo complexo. Sem saber previamente qual seria a “melhor” divisão dos dados, os cientistas de dados usam métricas específicas para verificar a coesão e a separação entre os clusters formados. Abaixo estão algumas das principais métricas de avaliação:

Soma dos Erros Quadráticos Internos (SSE): Também conhecida como Soma dos Quadrados dos Erros, essa métrica calcula o somatório das distâncias ao quadrado de cada ponto até o centro do seu cluster, dado por

$$SSE = \sum_{i=1}^n (x_i - x_c)^2. \quad (4)$$

É calculado a distância entre a posição de cada amostra x_i e a posição de seu respectivo cluster x_c . Quanto menor o valor do SSE, mais compactos e homogêneos são os clusters, sugerindo um bom agrupamento. A função de minimização do K-means, por exemplo, visa reduzir o SSE ao longo de suas iterações.

Método do Cotovelo: Baseia-se na análise do Soma dos Erros Quadráticos Internos (SSE), também conhecida como Inércia. Esse valor mede a variabilidade dos dados dentro dos agrupamentos, ou

seja, a soma das distâncias ao quadrado de cada ponto até o centroide de seu respectivo cluster. Em geral, quanto menor o SSE, mais compactos e coesos são os clusters.

A forma de aplicar o método do cotovelo passa pelo cálculo da SSE, conforme (4), seguindo uma ordem:

1. Executar o K-means para diferentes valores de K : O algoritmo K-means é executado várias vezes, com valores de K variando de 1 até um número razoável (por exemplo, de 1 a 10 ou de 1 a 15, dependendo do problema).
2. Calcular o SSE para cada K : Para cada execução, calcula-se o SSE dos clusters formados. À medida que K aumenta, o SSE tende a diminuir, pois os clusters tornam-se menores e mais específicos, o que leva a uma compactação maior dentro dos clusters.
3. Analisar o gráfico do SSE em função de K : Após calcular o SSE para cada valor de K , um gráfico é plotado, com K no eixo X e o SSE no eixo Y. Esse gráfico geralmente mostra uma curva decrescente.
4. Identificar o “cotovelo” da curva: A curva no gráfico tende a ter uma inflexão (ou “cotovelo”) em algum ponto, onde a redução no SSE começa a ser menos significativa à medida que K aumenta. Esse ponto de inflexão representa o ponto onde a adição de novos clusters começa a trazer menos benefícios, ou seja, os clusters adicionais não reduzem substancialmente o SSE.

O valor de K no “cotovelo” é considerado o número ideal de clusters, pois a partir desse ponto a criação de novos clusters não melhora significativamente a coesão dos dados dentro dos clusters.

Coefficiente de Silhueta: Este coeficiente mede a proximidade de um ponto dentro de um cluster em relação aos pontos em outros clusters. Ele varia de -1 a 1, onde valores próximos de 1 indicam que os pontos estão bem agrupados, enquanto valores negativos sugerem que os pontos podem estar no cluster errado. A fórmula para o coeficiente de silhueta é:


$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}, \quad (5)$$

Onde $a(i)$ é a distância média entre o ponto i e todos os outros pontos no mesmo cluster, e $b(i)$ é a menor distância média entre o ponto i e todos os pontos de qualquer outro cluster.

Essas métricas ajudam a determinar se os clusters formados representam adequadamente os dados e se os pontos dentro dos clusters são, de fato, semelhantes entre si. Em alguns casos, mais de uma métrica pode ser combinada para obter uma avaliação mais robusta dos resultados de agrupamento. Uma dica valiosa é não se apegar ao indicador. Sempre avalie qual é a influência de cada um em seu problema.

Ambos o método do cotovelo quanto o coeficiente de silhueta podem ser utilizados para definir o melhor número de clusters. Entretanto, a medida de silhueta apresenta uma análise mais completa dos agrupamentos, se for feita amostra por amostra.

Figura 3: Métricas para análise do número de clusters.




Fonte: Adaptado de Raschka et al. [4].

A Figura 3 apresenta estas métricas de avaliação para o algoritmo da Fig. 2b. A Fig. 3a apresenta a curva de cotovelo e a Fig. 3b, o diagrama de silhueta para $k = 3$ clusters. É possível notar que, conforme mencionado no anteriormente, para $k = 3$ clusters, o cotovelo fica nítido, mostrando que, para valores maiores do que 3 clusters, a inércia não apresenta grande diminuição. Já na Fig. 3b, os coeficientes de

silhueta, calculados amostra por amostra, mostra que os agrupamentos foram bem feitos, com divisões uniformes, retratados pelo formato de faca da curva. A espessura dos grupos indica que eles são aproximadamente de mesmo tamanho e o formato de faca sem quebras mostra que o grupo não possui valores destoantes (outliers) do resto do grupo. Como nenhuma das amostras apresentou coeficiente de silhueta negativo, é possível dizer que todas foram agrupadas de forma correta.

Conforme é possível ver na Figura 4, o agrupamento realizado pelo algoritmo com $k = 2$ clusters, mostrado na Fig. 4a, selecionou conjuntos distantes no espaço amostral como apenas um conjunto. O Diagrama de Silhueta deste algoritmo mostra na Fig. 4b que um dos clusters foi bem agrupado, mas o outro não está com uma distribuição uniforme de distância entre as amostras e o centroide. A maior parte

Figura 4: Métricas para análise do número de clusters ruim.



Fonte: Adaptado de Raschka et al. [4].

dos coeficientes de silhueta das amostras do Cluster 2 estão abaixo do coeficiente global do algoritmo. Ainda, é possível verificar dentes na faca, evidenciando que a escolha de 2 clusters não ter sido a melhor escolha.

2.5 Limitações do K-means

Número de clusters (K): Uma das principais limitações do K-means é que o número de clusters K precisa ser definido previamente. Em muitos casos, o número ideal de clusters não é conhecido e deve ser determinado por métodos de validação, como o método do cotovelo, que verifica a diminuição da variação interna dos clusters à medida que K aumenta.

Sensibilidade a outliers: O K-means é sensível a outliers, que podem distorcer a posição dos centroides e afetar a qualidade do agrupamento. Isso ocorre porque o algoritmo utiliza a média para calcular os centroides, o que pode ser afetado por valores extremos. Para mitigar esse problema, pode-se utilizar técnicas de pré-processamento, como remoção de outliers.

Clusters de forma específica: O K-means funciona melhor com clusters de formato esférico e tamanho semelhante, pois ele assume implicitamente que os clusters têm uma distribuição aproximadamente isotrópica (igual em todas as direções). Em casos onde os clusters têm formas complexas ou tamanhos muito diferentes, o K-means pode apresentar dificuldades para separar adequadamente os grupos. Alternativas como o DBSCAN (Density-Based Spatial Clustering of Applications with Noise) podem ser mais adequadas para dados com clusters de formas arbitrárias.

Dependência da inicialização: A qualidade dos resultados do K-means pode depender da escolha inicial dos centroides. Uma má inicialização pode levar o algoritmo a convergir para mínimos locais, produzindo clusters de baixa qualidade. A inicialização K-means++ é uma técnica que pode melhorar a escolha inicial dos centroides, aumentando a probabilidade de alcançar um bom agrupamento.

Dependência da métrica de similaridade: O resultado do agrupamento depende da métrica de distância. Alguns algoritmos funcionam melhor com certos tipos de dados e métricas específicas, o que pode exigir experimentação para obter o melhor resultado.

2.6 Aplicações

O algoritmo K-means possui uma ampla gama de aplicações em diversos campos e é uma ferramenta poderosa para agrupar e explorar dados não rotulados. Algumas delas são:

Exploração de dados: O clustering é particularmente útil para explorar grandes volumes de dados não rotulados, ajudando a detectar padrões e agrupamentos que não são imediatamente aparentes.

Descoberta de agrupamentos naturais: O agrupamento pode revelar estruturas ou grupos naturais dentro dos dados, o que pode ajudar em análises posteriores e em tomadas de decisão mais informadas.

Redução de dimensionalidade e resumo de dados: Agrupar dados em clusters pode servir como uma forma de simplificação, representando grandes quantidades de dados complexos com poucos grupos representativos. Isso facilita a análise, interpretação e visualização de dados complexos.

Segmentação de imagens: Em processamento de imagens, o K-means é utilizado para agrupar pixels com base em características de cor, intensidade, ou textura, simplificando a imagem em regiões homogêneas.

Agrupamento de documentos: Em análise de texto, K-means pode agrupar documentos com base em similaridades de conteúdo, auxiliando na organização e classificação de grandes volumes de textos, como artigos ou publicações.


Análise de clientes: No marketing, o K-means é amplamente utilizado para segmentar clientes com características semelhantes, como comportamento de compra, localização geográfica, ou preferências de produto. Essa segmentação permite o desenvolvimento de campanhas direcionadas e estratégias de marketing personalizadas.

Deteção de anomalias: Em finanças e segurança, o K-means pode ajudar a identificar atividades atípicas ou anômalas, agrupando dados “normais” e detectando outliers que não pertencem a nenhum cluster.

2.6.1 Segmentação de imagens

O algoritmo K-means foi utilizado em [9] para criar uma máscara de segmentação de imagens, conforme mostrado na Figura 5.

Figura 5: Aplicação do algoritmo K-means como segmentador de imagens.




Fonte: Adaptado de Santana-Neto et al. [9].

A primeira imagem apresenta discos de folhas de café que precisam ser separadas para compor um banco de dados. A segunda imagem mostra a transformação da primeira imagem para uma escala de verde. A terceira imagem mostra a seleção de tudo que não era disco, como se a imagem fosse separada, pixel a pixel, em dois grupos, disco e não disco. Por fim, na última imagem, a imagem original teve todos os pixels “não disco” zerados, podendo destacar apenas os pixels dos discos.

2.7 Outras considerações sobre o K-means

O K-means é amplamente utilizado devido à sua simplicidade, mas é sempre importante realizar uma análise cuidadosa dos dados e das condições de aplicação. Em alguns casos, é útil rodar o K-means várias vezes com diferentes inicializações e valores de K , comparando os resultados por meio de métricas



de avaliação, como o coeficiente de silhueta, para determinar a configuração que melhor representa a estrutura dos dados.

Para casos em que o K-means não se adapta bem, outras técnicas de agrupamento, como o K-medoids, DBSCAN, ou o Mean Shift, podem ser exploradas para superar suas limitações, especialmente em cenários com clusters de tamanhos ou formas não convencionais, presença de ruído ou alta variabilidade nos dados.

Referências

- [1] C. M. Bishop, “Pattern recognition and machine learning,” *Springer Google Scholar*, vol. 2, pp. 1122–1128, 2006.
- [2] W. I. D. Mining, “Data mining: Concepts and techniques,” *Morgan Kaufmann*, vol. 10, no. 559-569, p. 4, 2006.
- [3] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg *et al.*, “Scikit-learn: Machine learning in python,” *The Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [4] S. Raschka, Y. H. Liu, and V. Mirjalili, *Machine Learning with PyTorch and Scikit-Learn: Develop machine learning and deep learning models with Python*. Packt Publishing Ltd, 2022.
- [5] A. Géron, *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow*. O’Reilly Media, Inc., 2022.
- [6] D. Arthur and S. Vassilvitskii, “k-means++: The advantages of careful seeding,” Stanford, Tech. Rep., 2006.
- [7] J. MacQueen, “Some methods for classification and analysis of multivariate observations,” in *Proceedings of 5-th Berkeley Symposium on Mathematical Statistics and Probability/University of California Press*, 1967.
- [8] T. Terfrüchte and S. Frank, “Delineating and typifying urban neighbourhoods: A mixed-methods approach,” *Metropolitan Research*, p. 343, 2022.
- [9] A. T. Santana-Neto, P. M. R. Cardoso, E. G. Brenes, E. T. C. Moura, R. V. A. Neves, and L. B. Felix, “Coffeerust: An image database for classification of coffea arabica resistance to coffee leaf rust,” in *Anais do XXV Congresso Brasileiro de Automática-CBA*, Rio de Janeiro, 2024.