

Universidade Federal de Viçosa

Reitor

Demetrius David da Silva

Vice-Reitora

Rejane Nascentes



Diretor

Francisco de Assis de Carvalho Pinto

Campus Universitário, 36570-900, Viçosa/MG

Telefone: (31) 3612 1251

Layout: Ana Luísa Medeiros e Stéfany Peron

Editoração Eletrônica: Ana Luísa Medeiros

Edição de conteúdo e CopyDesk: João Batista Mota



Significado dos ícones da apostila

Para facilitar o seu estudo e a compreensão imediata do conteúdo apresentado, ao longo de todas as apostilas, você vai encontrar essas pequenas figuras ao lado do texto. Elas têm o objetivo de chamar a sua atenção para determinados trechos do conteúdo, com uma função específica, como apresentamos a seguir.



DESTAQUE: são definições, conceitos ou afirmações importantes às quais você deve estar atento.



GLOSSÁRIO: Informações pertinente ao texto, para situá-lo melhor sobre determinado termo, autor, entidade, fato ou época, que você pode desconhecer.

SAIBA MAIS: se você quiser complementar ou aprofundar o conteúdo apresentado na apostila, tem a opção de links na internet, onde pode obter vídeos, sites ou artigos relacionados ao tema.



PARA REFLETIR: vai fazer você relacionar um tópico a uma situação externa, em outro contexto



Exercícios Propostos: são momentos pra você colocar em prática o que foi aprendido

3. Máquinas de Vetores de Suporte (SVM)

Vamos iniciar a construção de nossa maleta de ferramentas inteligentes de aprendizado de máquinas com a máquina de vetor de suporte. Essa é a primeira ferramenta que veremos na disciplina *ELT 574 – Aprendizado de Máquinas* e o primeiro algoritmo com aprendizagem supervisionada.

Máquinas de vetores de suporte - do inglês *support vector machine* (SVM) - são algoritmos de aprendizado de máquina, que, a princípio, foram desenvolvidos para resolver problemas de classificação binários. Problemas de classificação binária são aqueles que envolvem classes rotuladas de duas maneiras: Classe A e Classe B ou Verdadeiro e Falso, por exemplo. Entretanto, com o desenvolvimento da técnica e do algoritmo, os vetores de suporte também são capazes de resolver problemas de regressão, por meio da regressão por vetores de suporte, do inglês *support vector regression* (SVR).

1. CONCEITO DE MARGEM E VETOR SUPORTE

O funcionamento das SVMs é baseado nos vetores de suporte (*support vectors*) que delimitam o espaço de separação das características das amostras de diferentes classes. A Figura 4 apresenta a representação dos vetores de suporte, que determinam as fronteiras do que pode ser classificado para além deles. No caso dessa figura, os vetores de suporte estão posicionados sobre a amostra com características mais extremas do banco de dados.




Figura 4 – Espaço de características e definição dos vetores de suporte e do hiperplano de separação para uma SVM de margem rígida (*hard margin*)

Entre os vetores de suporte, está posicionado o hiperplano de suporte. Ele é o responsável por fazer a separação do espaço de características para que as amostras possam ser classificadas de maneira correta.

As distâncias entre o hiperplano e os vetores de suporte são denominadas como margem. Suponha que, na Figura 4, as bolinhas verdes recebessem o valor +1 e as estrelas azuis o valor -1. Assim, a margem para o vetor de suporte +1 e -1 seria denominada D_+ e D_- , respectivamente.



objetivo do ajuste em uma SVM é encontrar as maiores margens possíveis para melhor classificar as amostras que pertençam a cada classe. Em outras palavras, encontrar um hiperplano de suporte que maximize as margens do espaço de características de um determinado problema.

2. SVM LINEARES

A maneira mais simples de aplicar o algoritmo de aprendizado de máquinas SVM é ajustar os parâmetros de um hiperplano linear que faça a correta classificação das amostras. A partir de conjuntos de amostras K com n amostras, na qual cada uma delas é representada pelo conjunto (x_k, y_k) . No caso, $x_k \in X$ é o vetor de característica da amostra e $y_k \in Y$ o rótulo desta amostra, tal que $Y = \{-1, +1\}$. Um hiperplano linear que divide o espaço de características para classificar cada amostra de maneira correta pode ser definido, matematicamente, como

$$f(x) = w \cdot x + b = 0$$

em que w é o vetor normal ao hiperplano, x é um conjunto de pontos sobre o hiperplano e b é a distância do hiperplano até a origem do espaço de características. As dimensões dos vetores w e x dependem da dimensão do espaço de características do problema em questão.

Considerando o exemplo da Figura 4, o hiperplano divide o espaço de características de maneira que, dado uma amostra x_k , se $f(x_k) = w \cdot x_k + b > 0$, a amostra é classificada como +1 (bolinha). Caso contrário, se $f(x_k) = w \cdot x_k + b < 0$, a amostra é classificada como -1 (estrela). Esta regra de classificação pode ser traduzida por:

$$g(x_k) = \text{sin}(\text{f}(x_k)) = \begin{cases} +1 & \text{se } w \cdot x_k + b > 0 \\ -1 & \text{se } w \cdot x_k + b < 0 \end{cases}$$

A partir desta definição, é possível traçar infinitos hiperplanos capazes de separar o espaço de características. Então, precisamos definir algum critério para a escolha do melhor hiperplano, o hiperplano ótimo, por meio do ajuste do vetor normal w e da distância entre o hiperplano e a origem b .

2.1. SVM de margem rígida

Na máquina de vetor de suporte, vamos escolher as amostras situadas nas extremidades mais próximas para definir os vetores de suporte e, então, definir o hiperplano ótimo que separa o espaço de características por meio dos ajustes em w e b . Isso significa que se os vetores de suporte forem definidos, e ambos forem normais ao vetor w , serão paralelos entre si.

Então, matematicamente, a condição que deve ser satisfeita pelos parâmetros do hiperplano é que:

$$|w \cdot x_k + b| = 1$$

Ou, ainda, para ficar mais clara a condição de restrição que estamos impondo com a escolha das amostras localizadas sobre cada vetor suporte:

$$\begin{cases} w \cdot x_k + b \geq +1, & \text{para } y_k = +1 \\ w \cdot x_k + b \leq -1, & \text{para } y_k = -1 \end{cases}$$

As duas condições dos vetores de suporte podem ser combinadas como uma única condição para facilitar o ajuste dos parâmetros do hiperplano. O resultado da combinação é:

$$y_k(w \cdot x_k + b) \geq 1, \text{ para } k = \{1, 2, \dots, n\}$$

A distância entre os vetores de suporte que passam pelas amostras selecionadas é mostrada na Figura 5. Seja ρ o módulo da distância entre os hiperplanos H_1 e H_2 , dada pela soma de D_- e D_+ , projetada na direção de w , tal que:

$$\rho = \frac{2}{\|w\|}$$

Então, podemos definir as distâncias entre os hiperplanos H_1 e H_2 do hiperplano de separação H_0 como as margens geométricas do classificador linear:

$$D_+ = D_- = \frac{1}{\|w\|}$$




Figura 5 – Definição dos hiperplanos definidos pelos vetores de suporte e as distâncias entre o hiperplano de separação e os vetores de suporte

Portanto, o objetivo do algoritmo SVM é encontrar os valores de w para que a margem entre o hiperplano de suporte e os vetores de suporte sejam máximas. Isto é feito buscando minimizar o valor de $\|w\|$ a partir do conjunto de amostras de determinado problema.

A partir daí, podemos enunciar o problema de otimização (primal), dado por:

$$\begin{cases} \textbf{Problema} & \text{SVM Margem rídiga} & (\text{Primal}) \\ \textbf{Minimizar} & \frac{1}{2} \|w\|^2, & \text{em } w \text{ e } b \\ \textbf{Sujeito a} & y_k(w \cdot x_k + b) \geq 1, & \text{para } k = \{1, 2, \dots, n\}. \end{cases}$$

A relação $\frac{1}{2} \|w\|^2$ foi inserida para caracterizar o problema de otimização em um problema de otimização quadrático e o termo $\frac{1}{2}$ foi considerado por conveniência, para simplificar a operação durante a otimização. Por ser um problema quadrático, ele terá uma única solução, definindo o hiperplano ótimo de separação para o espaço de características.

Problemas de otimização quadráticos, convexos e de solução única, podem ser solucionados com a formulação de um problema dual, utilizando uma função Lagrangiana. Tal função engloba a função que será otimizada e as restrições a que ela está sujeita, ponderada por multiplicadores de Lagrange α_k , para cada uma das amostras k . Sendo assim, a função Lagrangiana é definida

por:

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{k=1}^n \alpha_k (y_k (\mathbf{w} \cdot \mathbf{x}_k + b) - 1)$$



A formulação do problema dual implica na maximização da função Lagrangiana, que pode ser feita maximizando os valores de α_k , problema dual, e minimizando os valores de $\mathbf{w}$ e b , problema primal. Para encontrar os valores que solucionam os problemas, podemos derivar a função Lagrangiana e encontrar seus pontos de derivadas parciais iguais a zero para as variáveis de interesse.

Para $\mathbf{w}$ tem-se:

$$\frac{\partial L(\mathbf{w}, b, \alpha)}{\partial \mathbf{w}} = \mathbf{w} - \sum_{k=1}^n \alpha_k y_k \mathbf{x}_k = 0 \Rightarrow \mathbf{w} = \sum_{k=1}^n \alpha_k y_k \mathbf{x}_k$$

E para b , tem-se:

$$\frac{\partial L(\mathbf{w}, b, \alpha)}{\partial b} = - \sum_{k=1}^n \alpha_k y_k = 0 \Rightarrow \sum_{k=1}^n \alpha_k y_k = 0$$

Substituindo as duas derivadas na função Lagrangiana, podemos formular o problema de otimização dual como

$$\left\{ \begin{array}{ll} \text{Problema} & \text{SVM Margem r diga} \\ \text{Maximizar} & \sum_{k=1}^n \alpha_k - \frac{1}{2} \sum_{k,l=1}^n \alpha_k \alpha_l y_k y_l \langle \mathbf{x}_k, \mathbf{x}_l \rangle, \\ \text{Sujeito a} & \begin{cases} \alpha_k \geq 0, \\ \sum_{k=1}^n \alpha_k y_k = 0 \end{cases} \end{array} \right. \quad \begin{array}{l} \text{(Dual)} \\ \text{em } \alpha \\ \text{para } k = \{1, 2, \dots, n\}. \end{array}$$

A solu  o do problema dual   atrativa, pois utiliza o produto escalar de amostras do conjunto de treinamento para encontrar a solu  o da otimiza  o. A partir da solu  o do problema dual, o valor da solu  o  tima α^* ser  determinado. Da restri  o do problema primal, temos que:

$$\alpha_k^* (y_k (\mathbf{w}^* \cdot \mathbf{x}_k + b^*) - 1) = 0, \text{ para } k = \{1, 2, \dots, n\}$$

s  ser  obedecida se $\alpha_k^* = 0$ para todas as amostras k que n o estiverem localizadas sobre os vetores de suporte. Ou seja, podemos definir um conjunto de amostras k que est o localizadas sobre os vetores de suporte, tal que $\mathbf{x}_k \in X_{VS}$, em que X_{VS} s o todos os pontos sobre os vetores de suporte. As solu  es do problema primal podem ser encontradas a partir de:

$$\mathbf{w}^* = \sum_{k=1}^n \alpha_k^* y_k \mathbf{x}_k, \text{ para } k = \{1, 2, \dots, n\}$$

e

$$b^* = \frac{1}{n_{VS}} \sum_{x_l \in X_{VS}} \left(\frac{1}{y_l} - \sum_{x_k \in X_{VS}} \alpha_k^* y_k \langle x_k, x_l \rangle \right)$$

Repare que a condição a que o problema de otimização está sujeito impede que só valham para amostras que estão depois do vetor de suporte. Caso alguma amostra tenha ruído ou o conjunto de características do problema não seja linearmente separável, a SVM de margem rígida não deve ser aplicada.


2.2.SVM de margens suaves

Em problemas reais, dados ruidosos e *outliers* estão presentes no banco de dados. Uma alternativa para lidar com estes dados é a utilização de SVM de margens suaves ou *soft margins*. O conceito de SVM de margens suaves parte do relaxamento das restrições da SVM de margem rígida, resultando na restrição:

$$y_k(\mathbf{w} \cdot \mathbf{x}_k + b) \geq 1 - \xi_k, \quad \text{com } \xi_k \geq 0, \quad \text{para } k = \{1, 2, \dots, n\}$$

O termo ξ_k indica o relaxamento na restrição dos vetores de suporte, permitindo que haja dados entre o vetor de suporte respectivo da amostra k e o hiperplano H_0 . A Figura 6 apresenta alguns casos em que amostras estão dentro da margem suave da SVM. Casos em que $\xi_k > 1$ permitem que a amostra seja classificada de maneira errônea e pode ser aplicado, caso seja necessário. Os casos de classificação errada também estão exemplificados na Figura 6.

A partir da consideração de que é possível ter amostras entre as margens definidas pelos vetores de suporte, o problema de otimização pode ser reformulado para:



{	Problema	SVM Margem suave	(Primal)
	Minimizar	$\frac{1}{2} \ \mathbf{w}\ ^2 + C \sum_{k=1}^n \xi_k,$	em $\mathbf{w}, b$ e ξ
	Sujeito a	$y_k(\mathbf{w} \cdot \mathbf{x}_k + b) \geq 1 - \xi_k, \quad \text{com } \xi_k \geq 0 \text{ e para } k = \{1, 2, \dots, n\},$	

Figura 6 – Máquina de vetor de suporte com margens suaves (*soft margins*). As margens suaves permitem que amostras sejam classificadas mesmo em posições entre o vetor de suporte e o hiperplano de separação

na qual a constante C representa um custo por cada erro de classificação para cada unidade

do resultado de $\sum_{k=1}^n \xi_k$.

Como pode ser observado, o problema de otimização também é quadrático, como no caso da SVM linear de margem rígida. Então, podemos formular o problema de otimização dual aplicando a função Lagrangiana, como anteriormente, resultando em:

$$\left\{ \begin{array}{ll} \text{Problema} & \text{SVM Margem suave} \\ \text{Maximizar} & \sum_{k=1}^n \alpha_k - \frac{1}{2} \sum_{k,l=1}^n \alpha_k \alpha_l y_k y_l \langle \mathbf{x}_k, \mathbf{x}_l \rangle, \\ \text{Sujeito a} & \begin{cases} 0 \leq \alpha_k \leq C, \\ \sum_{k=1}^n \alpha_k y_k = 0' \end{cases} \end{array} \right. \quad \begin{array}{l} \text{(Dual)} \\ \text{em } \boldsymbol{\alpha} \\ \text{para } k = \{1, 2, \dots, n\}. \end{array}$$

O problema é o mesmo que no caso da SVM linear de margem rígida, com a diferença que os multiplicadores Lagrangianos são limitados pelo custo do erro de classificação.

Seja $\boldsymbol{\alpha}^*$ a solução ótima para o problema de otimização dual e $\mathbf{w}^*$, b^* e ξ^* as soluções do problema primal, $\mathbf{w}^*$ pode ser calculada, novamente, por:

$$\mathbf{w}^* = \sum_{k=1}^n \alpha_k^* y_k \mathbf{x}_k, \text{ para } k = \{1, 2, \dots, n\}$$

e b^* , que deve ser calculado baseado nos valores localizados entre as margens dos vetores de suporte, tal que:

$$\mathbf{b}^* = \frac{1}{n_{VS: \alpha_k^* < C}} \sum_{\mathbf{x}_l \in X_{VS}} \left(\frac{1 - \xi_k^*}{y_l} - \sum_{\mathbf{x}_k \in X_{VS: \alpha_k^* < C}} \alpha_k^* y_k \langle \mathbf{x}_k, \mathbf{x}_l \rangle \right)$$

Já a solução ξ^* é determinada por:

$$\xi_k^* = \max \left\{ 0, 1 - y_k \sum_{l=1}^n \alpha_l^* y_l \langle \mathbf{x}_k, \mathbf{x}_l \rangle + \mathbf{b}^* \right\}$$

Da condição de restrição do problema dual, temos que

$$\alpha_k^* (y_k (\mathbf{w}^* \cdot \mathbf{x}_k + \mathbf{b}^*) - 1 + \xi_k^*) = 0$$

e

$$(C - \alpha_k^*) \xi_k^* = 0$$

Com estas condições, podemos classificar as diferentes amostras no espaço de características. Em todos os casos que as amostras pertencem ao vetor de suporte, $\alpha_k^* > 0$, pela primeira restrição. Considerando somente estes casos, podemos ainda classificar os vetores de suporte de acordo com os valores de C e ξ_k^* . Se $0 < \alpha_k < C$, então, pela segunda restrição, $\xi_k^* = 0$ e o vetor de suporte é classificado como livre. Caso $\alpha_k = C$, a classificação do vetor de suporte

depende somente de ξ_k^* , sendo que, se $\xi_k^* = 0$, a amostra é uma das amostras que definem os vetores de suporte. Se $0 < \xi_k < 1$, a amostra está dentro da margem entre o vetor de suporte e o hiperplano de suporte e, se $\xi_k > 1$, a amostra está do outro lado do hiperplano que define sua classe, sendo classificada de forma errada.



A solução deste problema de otimização resulta em um hiperplano ótimo que classifica as amostras no espaço de características do problema. A constante C é escolhida pelo desenvolvedor do algoritmo e pode ser utilizada como um parâmetro de busca que alcance o resultado desejado. Quanto maior o valor da constante, menor será a margem permitida pelos vetores de suporte.

Como dito anteriormente, caso o espaço de características traga amostras não linearmente separáveis, não é recomendada a aplicação de SVM Lineares, margem rígida ou suave. Nesses casos, a aplicação da máquina de vetor de suporte utiliza o truque de transformação do espaço de características, recebendo o nome de SVM não linear.

2.3. SVM não lineares e funções Kernel

O espaço de características de problemas reais é, em grande maioria, não linearmente separável. Um espaço não linearmente separável significa que não é possível separar as classes das amostras desse espaço com funções lineares, como a SVM linear. Por exemplo, a Figura 7 mostra um espaço de características que tem classes não linearmente separáveis.




Figura 7 – Espaço de características com classes não linearmente separáveis

Como é possível verificar, a **separação** das classes não linearmente separáveis por meio das SVM lineares, tanto a de margem rígida quanto a de margem suave, não consegue **separar** o espaço de caraterísticas sem classificar muitas amostras de maneira errada. Nesses casos, a aplicação do algoritmo de SVM é feito aliado a uma transformação do espaço de características, denominada




Figura 8 – Transformação do espaço de características de para pela função

. A Figura 8 exemplifica a transformação do espaço de características de X , Figura 8(a), para $\mathcal{H}$, Figura 8(b).

No exemplo da Figura 8, a função $\Phi(\cdot)$ transforma um espaço de características X de duas dimensões (x_1, x_2) para o espaço de características $\mathcal{H}$ de três dimensões (h_1, h_2, h_3) . Matematicamente, o mapeamento da Figura 8(a) para a Figura 8(b) é dado por:

$$\mathbf{h}_k = (h_{1,k}, h_{2,k}, h_{3,k}) = \Phi(\mathbf{x}_k) = \Phi(x_{1,k}, x_{2,k}) = (x_{1,k}^2, \sqrt{2}x_{1,k}x_{2,k}, x_{2,k}^2)$$

A partir daqui, aplica-se a SVM linear com margens suaves no espaço de características para garantir uma boa generalização de classificação. Aplicando os novos pontos para a equação do hiperplano da SVM linear, tem-se:

$$f(\mathbf{h}_k) = \mathbf{w} \cdot \Phi(\mathbf{x}_k) + b = w_1 x_{1,k}^2 + w_2 \sqrt{2} x_{1,k} x_{2,k} + w_3 x_{2,k}^2 + b = 0$$

Definida a função do hiperplano para as coordenadas do espaço de características $\mathcal{H}$, podemos definir os problemas de otimização primal e dual. Este procedimento segue a mesma ordem dos problemas de otimização da SVM linear com margem suave. O problema de otimização primal continua o mesmo, considerando a nova função hiperplano. O problema de otimização dual é formulado como:

$$\text{Maximizar}_{\alpha} \sum_{k=1}^n \alpha_k - \frac{1}{2} \sum_{k,l=1}^n \alpha_k \alpha_l y_k y_l \langle \Phi(\mathbf{x}_k), \Phi(\mathbf{x}_l) \rangle$$

na qual o produto $\Phi(\mathbf{x}_k) \cdot \Phi(\mathbf{x}_l)$ é o produto interno das coordenadas das amostras no novo espaço de características.



É importante lembrar que a transformação do espaço de características pode ser feita para infinitas dimensões, quantas sejam necessárias para a melhor generalização do algoritmo da SVM. Este aumento nas dimensões do espaço de características pode fazer com que o problema fique muito complexo e computacionalmente custoso.

Entretanto, o produto interno $\Phi(\mathbf{x}_k) \cdot \Phi(\mathbf{x}_l)$ pode ser feito por uma função que relaciona as coordenadas no espaço de características. Ou seja, uma função K , denominada função Kernel, calcula o produto interno das coordenadas das duas amostras de tal maneira que

$$K(\mathbf{x}_k, \mathbf{x}_l) = \langle \Phi(\mathbf{x}_k), \Phi(\mathbf{x}_l) \rangle$$

na qual $\Phi(\cdot)$ é a função de transformação do espaço de características. As funções Kernel permitem que algoritmos lineares solucionem problemas não lineares. Entre as funções Kernel mais comuns para aplicações de SVM estão as funções apresentadas na Tabela 1. A aplicação das funções não lineares para mapear o hiperplano no espaço de características originais do problema é denominado truque do Kernel, do inglês *Kernel trick*.

As funções presentes na Tabela 1 têm parâmetros que são ajustados pelo desenvolvedor do algoritmo. Esses parâmetros podem ser buscados por meio de uma busca paramétrica, de acordo com os critérios de desempenho exigidos pelo problema.

TABELA 1 - Funções Kernel encontradas com frequência na literatura

Tipo de Kernel Função	$K(\mathbf{x}_k, \mathbf{x}_l)$
Polinomial	$K(\mathbf{x}_k, \mathbf{x}_l) = (\delta \langle \mathbf{x}_k, \mathbf{x}_l \rangle + \beta)^p$
Gaussiana (RBF)	$K(\mathbf{x}_k, \mathbf{x}_l) = \exp\left(-\frac{\ \mathbf{x}_k - \mathbf{x}_l\ ^2}{2\sigma^2}\right)$
Sigmoidal	$K(\mathbf{x}_k, \mathbf{x}_l) = \tanh(\delta \langle \mathbf{x}_k, \mathbf{x}_l \rangle + \beta)$

3. CONSIDERAÇÕES FINAIS

Os algoritmos de aprendizagem de máquina baseados em máquinas de vetor de suporte são ferramentas robustas para o processamento de dados de grande dimensão. O truque do Kernel é um artifício poderoso para separar amostras não linearmente separáveis, utilizando uma função não linear, mas resolvendo um problema de margens suaves. O problema de otimização convexo garante que a solução do problema seja única, baseada nos dados de treinamento.

Como limitações deste tipo de algoritmo de aprendizado de máquinas, as escolhas dos parâmetros que compõem as funções de otimização podem limitar a capacidade de generalização do SVM. Outra limitação é a dificuldade de visualizar os espaços de características de muitas dimensões e interpretar a equação que define o hiperplano de separação.

Nas próximas etapas, vamos conhecer outros algoritmos e poderemos comparar a capacidade e complexidade dessas ferramentas para a solução de problemas envolvendo aprendizado de máquinas.



Coordenadoria de
Educação Aberta e a Distância