


Análise de imagens e visão computacional

Fabyano Fonseca e Silva



Universidade Federal de Viçosa

Reitor

Demetrius David da Silva

Vice-Reitora

Rejane Nascentes



Diretor

Francisco de Assis de Carvalho Pinto

Campus Universitário, 36570-900, Viçosa/MG

Telefone: (31) 3612 1251

Layout: Ana Luísa Medeiros e Stéfany Peron

Editoração Eletrônica: Ana Luísa Medeiros

Edição de conteúdo e CopyDesk: João Batista Mota



Significado dos ícones da apostila

Para facilitar o seu estudo e a compreensão imediata do conteúdo apresentado, ao longo de todas as apostilas, você vai encontrar essas pequenas figuras ao lado do texto. Elas têm o objetivo de chamar a sua atenção para determinados trechos do conteúdo, com uma função específica, como apresentamos a seguir.



DESTAQUE: são definições, conceitos ou afirmações importantes às quais você deve estar atento.



GLOSSÁRIO: Informações pertinente ao texto, para situá-lo melhor sobre determinado termo, autor, entidade, fato ou época, que você pode desconhecer.


SAIBA MAIS: se você quiser complementar ou aprofundar o conteúdo apresentado na apostila, tem a opção de links na internet, onde pode obter vídeos, sites ou artigos relacionados ao tema.



PARA REFLETIR: vai fazer você relacionar um tópico a uma situação externa, em outro contexto



Exercícios Propostos: são momentos pra você colocar em prática o que foi aprendido



Sumário

Apresentação	8
1. Análise exploratória de dados de imagens	9
2. IA para reconhecimento de padrões e classificação de imagens	13
3. Conceitualização de visão computacional	18
4. Redes convolucionais aplicadas à visão computacional	20
Referências	22




Currículo

Fabyano Fonseca e Silva

É graduado em Zootecnia (2001) e tem mestrado (2003) e doutorado em Estatística, todos os diplomas obtidos na Universidade Federal de Lavras (UFLA). Foi pesquisador da University of Wisconsin-USA (2008-2010), da Universidad de Zaragoza-Espanha (2011) e da University of Wageningen-Holanda (2012).

Desde 2013, é Professor Associado IV, do Departamento de Zootecnia da UFV. Atualmente, atua como Pesquisador 1A CNPq, nas áreas de Ambientômica, Informações GIS e genômicas para a aplicação na pecuária.

Contato: fabyanofonseca@ufv.br



Apresentação

Aprendizado de máquina é um dos campos relacionados com a Ciência da Computação e, atualmente, suas técnicas são a base da maioria dos métodos utilizados em processamento e análise de imagens e visão computacional.

Portanto, entender e ser capaz de acompanhar os desenvolvimentos atuais da área é de fundamental importância na formação do estudante. (...)



1. Análise exploratória de dados de imagens

Embora tenha sido utilizada em várias áreas da ciência, dados caracterizados por imagens têm mostrado sérias restrições quanto à sua capacidade de capturar, de forma efetiva, as características da cena reportada (variáveis de entrada).

Segundo STEFFENS et al. (2019), tais restrições ficam mais claras quando se considera, por exemplo, uma cena com iluminação insuficiente, com objetos de superfície reflexiva ou, até mesmo, com alto contraste. Portanto, é comum deparar-se com imagens digitais nas quais alguma parte do conteúdo não está apropriadamente visível.

A relação entre as estatísticas de uma imagem e as suas propriedades visuais aparentes vem sendo explorada por diversos autores, como STEFFENS et al. (2019). Destacam-se os trabalhos que fornecem os subsídios teóricos, experimentais e metodológicos para o desenvolvimento das análises exploratórias.

Os conceitos estatísticos para análise exploratória de imagem vêm sendo utilizados com as finalidades de aumentar a compreensão sobre a estrutura do sistema visual humano e desenvolver técnicas de representação e codificação eficientes, a fim de verificar como as características estão associadas às propriedades visíveis de superfícies e estruturas.



Nesse contexto, a inferência estatística é empregada para identificar as propriedades de imagens, levando em consideração a capacidade computacional, sob o ponto de vista de Inteligência Artificial (principalmente em relação à quantidade de neurônios e restrições de conectividade). Uma vez que existe uma capacidade restrita, é natural assumir que o sistema evolui para se adaptar aos sinais aos quais estatisticamente respondem a uma maior exposição (nesse caso, frequência de pixels).

Tais premissas são justificadas a partir da teoria estatística da informação, a mesma evidenciada por SIMONCELLI E OLSHAUSEN (2001) e generalizada por STEFFENS et al. (2019). Segundo estes autores, uma das metodologias mais utilizadas para o treinamento de modelos de predição/restauração/validação de imagens é aquela baseada em redes neurais convolucionais (RNC). Essa metodologia requer amostras delineadas para treinamento, em que cada amostra é composta por uma entrada e uma saída esperada.

De acordo com GOODFELLOW et al. (2014), dentre várias situações complexas envolvendo o delineamento de amostras de treinamento, destaca-se o conceito de GANs (*Generative Adversarial Network*). Ele associa duas redes neurais no arranjo gerador-discriminador.

- **Rede discriminadora:** aprende a classificar dados entre duas classes (real ou falsa)
- **Rede geradora:** aprende a validar a rede discriminadora e a gerar um dado classificado como real, de forma que ambas aprendam de maneira conjunta. Ao final do treinamento, apenas a rede geradora é utilizada para aplicação.

Apesar de obter excelentes resultados, o treinamento de GANs tem um alto custo computacional, uma vez que duas redes neurais precisam ser treinadas ao mesmo tempo.

Diante da grande variedade de definições necessárias para o pleno entendimento da “Análise exploratória de dados de imagens”, serão apresentados alguns conceitos básicos.

A Resolução Espacial é a transição para o “universo” digital e depende essencialmente de um processo amostral confiável. Pretende-se explorar um pouco mais essa questão, assim como seu

problema inverso, o de reconstrução da imagem original.

Serão também abordadas situações nas quais a definição de reconstrução é análoga à técnica de interpolação. A definição cor e como abordar tal definição sob o ponto de vista computacional também serão explorados no presente material, bem como o estudo aprofundado de vários padrões pré ou não estabelecidos que as definam.

Adicionalmente, os conceitos de Luminância e Crominância, assim como outras propriedades de cor, também serão contemplados de forma prática e objetiva. O termo Visualização será estudado sob os pontos de vista estatístico e computacional. Isso porque, uma vez que a imagem tenha sido digitalizada, o objetivo central será reconstruí-la em alguma **superfície de visualização**.

Embora existam várias perspectivas para o conceito computacional de “armazenamento de informações”, torna-se necessário explorar aspectos relacionados com a imagem, antes que ela seja armazenada na memória do computador. Da mesma forma, as diferentes formas de armazenamento e otimização dos recursos computacionais empregados nesta tarefa também devem ser explorados.



De acordo com STEFFENS et al. (2019), é importante ressaltar que, apesar da relevância e ampla utilização de sistemas baseados em imagens, faz-se necessário destacar que sensores de imagem apresentam sérias restrições quanto à sua capacidade de capturar as características de interesse.

Tais restrições ficam mais claras quando se considera, por exemplo, uma imagem com iluminação insuficiente, com objetos de superfície reflexiva ou, até mesmo, **com ruídos de contraste**. Em resumo, é comum deparar-se com imagens digitais na quais algumas partes do conteúdo não estão apropriadas para a análise.

Sistemas que monitoram o desempenho individual de produção (industrial, saúde, animal, vegetal, etc.) por meio da coleta e armazenamento de imagens digitais tridimensionais (tal como o Kinect®) são muito atrativos diante da praticidade (automação das medições) e acessibilidade (relativamente de baixo custo) na obtenção de informações úteis para a tomada de decisão.

Contudo, não é possível analisar diretamente dados de imagens via modelos estatísticos. Portanto, a análise de imagem necessita de um pré-processamento, o qual está fundamentado na filtragem dos dados direcionada para a detecção e remoção de ruídos.

Após a filtragem, é possível extrair atributos das imagens, que se caracterizam como medidas (geralmente, área, comprimento, largura, altura e volume) que serão posteriormente correlacionadas com o denominado “padrão-ouro” (medidas diretas ou instrumentais), proveniente de aferições realizadas em instrumentos básicos, dependendo da área de interesse (balanças, paquímetros, fitas métricas, ultrassom e outros instrumentos básicos de mensurações biométricas).

1. SISTEMA KINECT®

Um exemplo é o sistema Kinect®, o qual foi o sensor de movimento pioneiro a ser comercializado e empregado em produção industrial (STOWERS et al., 2011). Ele ocorreu via utilização de uma câmera RGB (*red, green and blue*) e uma câmera IR (*infra red*), as quais reportam imagens digitalizadas (intensidade dos *pixels*), calculando a distância entre o ponto focado e o dispositivo.

A vantagem do Kinect® para a geração de imagens tridimensionais, em vez de bidimensionais, é que não só informações de contorno podem ser processadas; também as alterações nas superfícies dos animais podem ser examinadas detalhadamente (WEBER et al. 2014).

Apenas como exemplo, um dos conjuntos de dados a serem empregados, para promover os conceitos da análise de imagens e visão computacional, dispõe de imagens digitais geradas por Kinect®. Sua câmera infravermelha tem uma resolução de 640x480 pixels e gera 30 imagens por segundo. O campo de visão do sensor de profundidade é de 57° na horizontal e 43° verticalmente,

podendo ser operados entre 0,8 e 4,0 m de distância. Para cada um dos animais avaliados, também foram obtidas mensurações convencionais (cotidianamente denominadas de “padrão-ouro”) para as características de rendimento de carcaça, espessura de toucinho e área de olho de lombo.

Diante dessas informações, será possível avaliar a habilidade do dispositivo Kinect® em prever os dados fenotípicos, via imagens digitais. A vantagem da análise de imagens, nesse caso, é evidenciada pela dinâmica de mensuração. Isso porque os animais não precisam passar por aferições fenotípicas provenientes diretamente da ação humana (imobilização do animal e subsequentes medições com ultrassom para espessura de gordura e área de olho de lombo, além de avaliações métricas na carcaça após o abate).

Sistemas, como o Kinect®, “fotografa” os produtos de interesse em diferentes ângulos quando eles passam livremente por corredores funcionais dentro das granjas (Figura 1). Portanto, tem-se um aprimoramento da logística, devido à redução de tempo e custos referentes ao processo de fenotipagem convencional. Além disso, reduz o estresse dos animais quando submetidos aos processos de avaliações convencionais (mensurações manuais), como pesagens e medições corporais.



Figura 1. Ilustração do sistema Kinect® empregado para gerar os dados de imagens digitais utilizadas em um sistema industrial de produção de suínos (adaptado de KONGSRO, 2014)

A fase de filtragem é muito importante, pois elimina ruídos que existem na imagem gerada pelo Kinect®, proporcionando uma imagem mais suave e real (PEZZUOLO et al., 2018). Em síntese, a filtragem visa gerar uma imagem menos “poluída” que a original, por meio da definição de pesos (importâncias) dos *pixels*. Dessa forma, promove o maior ou menor realce da cena (ou *frame*), segundo as direções preferenciais de interesse. Tal processo de ponderação dos *pixels* pode ser realizado por diferentes ferramentas estatístico-computacionais, dentre as quais os algoritmos de filtros adaptativos são os mais utilizados.




Figura 2. Ilustração do processo de filtragem, de forma que em (A) tem-se a imagem original gerada pelo Kinect[®], e em (B) a imagem filtrada por meio de redes neurais artificiais (adaptado de PEZZUOLO et al., 2018)

Em resumo, os “filtros adaptativos” são definidos por algoritmos que calculam as importâncias (pesos) dos *pixels* de forma recursiva. No presente projeto, serão utilizados “filtros adaptativos não-supervisionados”. Neles, os pesos dos *pixels* são estimados, sem a necessidade de fixar uma resposta (padrão de qualidade da imagem) desejado ou predefinida. A estrutura do filtro a ser utilizada e o algoritmo empregado em sua adaptação constituem os problemas fundamentais na filtragem adaptativa.

A estrutura do filtro é selecionada, a fim de melhor produzir um sinal de saída como resposta a uma sequência de dados de entrada, de forma que o sinal de saída contenha informações que balizem o processo de adaptação. Existem diferentes propostas na literatura, mas uma generalização bastante funcional é representada pelos filtros adaptativos não-supervisionados, via algoritmo de difusão não-linear, considerando a estrutura de correlação espacial entre os pixels (POLZEHL & TABELOW, 2017). Tais métodos de filtragem (suavização) são facilmente implementados, via pacote *adimpro* (*Adaptive Smoothing of Digital Images*, ou “Suavização adaptativa para imagens digitais”) do *software* R (R Core Team, 20).



2. IA para reconhecimento de padrões e classificação de imagens

Após a filtragem, é necessário extrair os denominados “atributos” das imagens. No exemplo adotado até agora de mensurações corporais de suínos, os atributos se caracterizam como medidas (área, comprimento, largura, altura e volume) de regiões específicas dos animais que serão posteriormente correlacionadas com o “padrão-ouro” (medidas diretas ou instrumentais), já mencionado anteriormente. Quanto mais eficiente for o processo de filtragem dos *pixels*, mais precisa será a extração dos atributos utilizados no processo de predição dos fenótipos de interesse (rendimento de carcaça, espessura de toucinho e área de olho de lombo).

Os seguintes atributos geralmente são extraídos em estudos envolvendo animais de produção, tal como o exemplo de avaliação de suínos destacada neste material:

- 1 mensuração de área e uma de comprimento,
- 11 mensurações de largura ao longo do dorso,
- 11 medidas de altura ao longo do dorso, e
- 11 medidas de volume corporal nos pontos de altura e largura.

Dessa forma, tem-se, ao todo, um total de 35 variáveis explicativas provenientes da imagem Kinect®, previamente filtradas para serem associadas com os dados do “padrão-ouro”. A Figura 3 ilustra todos os atributos a serem considerados.

Em resumo (Figura 3), os 35 atributos originais, se combinados 2 a 2, irão gerar um número total de 595 combinações das variáveis preditoras (representando a interação linear-linear entre elas). Adicionalmente, também serão testadas 595 variáveis representadas pela interação linear-quadrática ($x_1 * x_2^2$); outras 595 dadas pela interação quadrática-linear ($x_1^2 * x_2$), e mais 595 caracterizando a interação quadrática-quadrática ($x_1^2 * x_2^2$). Dessa forma, tem-se um total de 2415 ($35 + 595 + 595 + 595 + 595$) variáveis preditoras.






Figura 3. Ilustração dos 35 atributos extraídos a partir das imagens filtradas de imagens corporais de suínos (exemplo adotado para fins didáticos no presente material). Tais atributos serão posteriormente utilizados na predição dos valores do “padrão-ouro”

Diante deste elevado número de variáveis, métodos de seleção de variáveis apresentam-se como ferramentas essenciais para evitar problemas de multicolinearidade e de sobreajuste (*overfitting*). Para tais situações, modelos de regressão múltiplas e redes neurais artificiais (RNA) de arquitetura simples não têm sido muito eficientes por não acomodarem uma seleção efetiva de variáveis (eliminação de variáveis redundantes).

Sob esta abordagem, as Redes Bayesianas Regularizadas (RBR) se destacam como uma alternativa viável para identificar as variáveis (por exemplo, dentre as 2415 inicialmente propostas) que garantam a melhor descrição possível das variáveis fenotípicas do “padrão-ouro”.

Em resumo, cada uma das variáveis do “padrão-ouro” (rendimento de carcaça, espessura de toucinho e área de olho de lombo) é considerada separadamente como variável resposta em análises, via RBR, assumindo as 2415 variáveis dos atributos como as preditoras.

Uma breve descrição das Redes Bayesianas Regularizadas (RBR) é apresentada a seguir. Inicialmente, a categoria de redes neurais mais simples e geralmente mais usada para redução de dimensionalidade em análises de imagens é denominada de *multilayer feed-forward perceptrons* (ou simplesmente, MLP).



Uma MLP de duas camadas (também denominada de *single hidden layer perceptron*) se aplica à maioria dos problemas estatísticos geralmente envolvidos em análise de imagens. Apresenta a vantagem de capturar relações não lineares, geralmente não capturadas por outras estruturas.




Figura 4. Representação gráfica de uma rede MLP de duas camadas (*single hidden layer perceptron*) com três neurônios na camada de transferência

Na Figura 4:

x_{ip} representa as variáveis ($p=1,2,...,P$) de entrada (matriz de *pixels* que representa a imagem após a filtragem);

$\omega_{1,p}$ é peso da variável de entrada p relacionado com cada um dos três neurônios da camada de transferência (também chamada de oculta);

$\omega_{2,s}$ é peso da variável transformada s ($s=1,2,...,S$), neste caso $S=3$, relacionado com cada a camada de saída;

y é o vetor de saída (output);

$f(.)$ é a função de ativação da camada de transferência;

$g(.)$ é a função de ativação da cama de saída;

Σ denota os cálculos de todos os neurônios;

viés1 indica o intercepto da camada oculta;

viés2 representa o intercepto da camada de saída.

Segundo HASTIE ET AL. (2009), a rede MLP em duas camadas pode ser vista como uma regressão em dois passos, como, por exemplo, a regressão em componentes principais, no qual, no primeiro passo, são obtidos os componentes e, no segundo, estes são considerados variáveis independentes no modelo de regressão.

Em se tratando da rede, a ideia central é extrair combinações lineares ou não lineares (ditadas pelas funções $f(.)$) das variáveis de entrada e utilizá-las como entrada na função $g(.)$ inerente à camada de saída.

A representação da rede na Figura 4 pode ser descrita algebricamente na forma de uma modelagem hierárquica como se segue:

$$z_i^{(s)} = f_s \left(a_s + \sum_{p=1}^P \omega_{1p}^{(s)} x_{ip} \right)$$

em que: $z_i^{(s)}$ é o valor resultante (denominado de escore) da transformação (ditada pela função $f_s(\cdot)$) das combinações (provenientes de cada neurônio s , $s=1,2,\dots,S$) entre as covariáveis

originais x_{ip} ; a_s é o intercepto de cada neurônio s ; $\omega_{1p}^{(s)}$ é o peso da covariável relacionada ao neurônio s na camada oculta.

A função de ativação $f_s(\cdot)$ pode ser linear ou não linear, mas deve ser monotonicamente crescente. A utilização de funções não lineares, como a tangente hiperbólica e logística, confere à rede uma flexibilidade muito maior que os modelos de regressão padrão. Quando aplicada à análise de imagens, é esta flexibilidade que confere às RNA a capacidade de capturar relações não lineares entre os *pixels* (ou conjunto de *pixels*), que podem culminar em maior precisão da imagem predita.

Sob o enfoque de MLP em duas camadas, os escores produzidos ($z_i^{(s)}$) na primeira camada são agora considerados covariáveis na camada de saída. O modelo para esta camada de saída é dado por:

$$y_i = g \left(b + \sum_{s=1}^S \omega_{2s} z_i^{(s)} \right) + e_i$$

em que: y_i é o valor fenotípico predito pela RNA, resultante da transformação ditada pela função $g(\cdot)$ aos escores $z_i^{(s)}$ produzidos pela camada oculta anterior, cujos pesos são agora dados por ω_{2p} considerando apenas um neurônio; b é o intercepto da camada de saída e e_i é o erro aleatório. Segundo GIANOLA et al. (2011), as duas camadas podem ser conjugadas, a fim de representar integralmente a RNA considerada. Esta representação é dada por:

$$y_i = g \left(b + \sum_{s=1}^S \omega_{2s} \left(f_s \left(a_s + \sum_{p=1}^P \omega_{1p}^{(s)} x_{ip} \right) \right) \right) + e_i$$

O termo treinamento da rede consiste, na verdade, em estimar os valores dos pesos e dos interceptos referentes a cada camada. Uma vez que se trata de uma rede supervisionada, isto é, sabe-se de antemão o resultado (valores fenotípicos conhecidos da população de treinamento), que vai ser comparado com os valores preditos, os valores desses “parâmetros” desconhecidos são obtidos iterativamente por meio de algoritmos de otimização (por exemplo, Levenberg-Marquardt), que visam minimizar a diferença entre o observado e o predito.

Embora esta dinâmica de redes neurais seja eficiente para previsões de imagens, algumas críticas quanto ao uso dessas redes têm sido reportadas na literatura (GIANOLA et al., 2011).

O principal motivo para tais críticas é que a maioria dos estudos sobre esta abordagem não apresenta informações sobre a estrutura da rede utilizada, fazendo com que esta técnica seja caracterizada como uma “caixa preta”. Além disso, provoca problemas relacionados ao sobreajuste (*overfitting*), o qual prejudica, de forma significativa, a predição de imagens na análise de validação.

Uma forma de resolver estes problemas é por meio da utilização de distribuições de probabilidades, para representar o conhecimento sobre os parâmetros a serem estimados em uma rede neural (nesse caso, os pesos e os interceptos). Assim, há uma mitigação do termo “caixa preta”, pois o processo passa a ser fundamentado em distribuições de probabilidade, e, portanto, recebe todo o crivo estatístico em sua descrição.



Quanto ao *overfitting*, é possível inserir uma regularização por meio da utilização de distribuições de probabilidade específicas, capazes de aproximar os pesos de certas variáveis para zero. Realiza-se, assim, uma seleção de variáveis implícita à rede neural.

Portanto, devido a esta relação íntima das redes com as distribuições de probabilidade, nada mais natural que utilizar a abordagem Bayesiana para executar esta fusão de informações. Tal fato cunhou a terminologia denominada de redes neurais Bayesianas (RNB) reportada neste material didático.

Sob o enfoque de redes neurais Bayesianas, considere Ψ como um vetor de parâmetros, que inclui os pesos e os interceptos de todas as camadas da rede apresentada na Figura 1; ou seja, $\Psi = [a_1, a_2, \dots, a_S, \omega_{11}, \omega_{12}, \dots, \omega_{1P}, b, \omega_{21}, \omega_{22}, \dots, \omega_{2S}]'$. Considere ainda que para esses parâmetros seja assumida a seguinte distribuição *a priori*,

$$P(\Psi | \sigma_{\Psi}^2) = \prod_{k=1}^{S+P+1+S} N(\Psi_k | 0 | \sigma_{\Psi_k}^2), \text{ e que a distribuição conjunta dos dados amostrais seja}$$

dada por:
se utilizar o

$$P(y | \Psi, \sigma_e^2) = N \left(y | g \left(b + \sum_{s=1}^S \omega_{2s} \left(f_s \left(a_s + \sum_{p=1}^P \omega_{1p}^{(s)} x_{ip} \right) \right) \right), \sigma_e^2 \right). \text{ Assim, ao}$$

teorema de Bayes tem-se:

$$P(\Psi | y, \sigma_{\Psi_k}^2, \sigma_e^2) = \frac{P(y | \Psi, \sigma_e^2) P(\Psi | \sigma_{\Psi}^2)}{P(y | \sigma_{\Psi_k}^2, \sigma_e^2)},$$

em que: $P(\Psi | y, \sigma_{\Psi_k}^2, \sigma_e^2)$ é a distribuição, *a posteriori*, dos parâmetros desconhecidos (pesos e interceptos de todas as camadas) e $P(y | \sigma_{\Psi_k}^2, \sigma_e^2)$ é a verossimilhança marginal, dada por:

$$\int P(\Psi | y, \sigma_{\Psi_k}^2, \sigma_e^2) d\Psi.$$

Para obter as estimativas dos parâmetros, pode-se utilizar o método MCMC (Cadeias de Markov via simulação Monte Carlo). No entanto, ele requer grande demanda computacional, o que o torna inviável neste contexto de Inteligência Artificial. Uma alternativa é a não utilização de amostragem por meio da estimação direta da moda *a posteriori*, via algoritmos de otimização.

Este enfoque é denominado *Empirical Bayes* e consiste na utilização dos dados amostrais para estimar os hiperparâmetros do modelo (neste caso $\sigma_{\Psi_k}^2$ e σ_e^2) e, assim, aproximar a moda da distribuição, *a posteriori*. As redes neurais Bayesianas podem ser executadas no *software* MATLAB (BEALE et al., 2011) e no pacote brnn (PEREZ-RODRIGUEZ et al., 2013) do *software* R.

Diante do exposto, as análises estatísticas padrão visam identificar, via RBR (identificadas, via análise de validação cruzada, a ser descrita posteriormente), aquelas aptas para fazerem as previsões de cada característica do “padrão-ouro”, com a intenção de utilizar futuramente apenas as medidas dos atributos extraídos das imagens para obter os valores de tais características. É neste passo que se personifica todas as vantagens já relatadas da análise de imagens, tal como a redução de tempo e custos referentes ao processo de mensurações convencionais.

3. Conceitualização de visão computacional

Uma das conceitualizações de visão computacional pode ser apresentada como a tarefa de treinar e ensinar computadores a enxergar como humanos, fornecendo ao computador informações precisas, por meio de imagens ou vídeos, de forma que seja possível executar tarefas inteligentes. Portanto, por meio desta definição é que temos esta forte associação entre visão computacional e Inteligência Artificial (SZELISKI, 2010; NIXON et al., 2012).

De forma geral, devido aos conteúdos apresentados neste material até agora, Visão Computacional trata da extração de informações das imagens e da identificação e classificação de objetos ou formas presentes na imagem. Esses sistemas envolvem diversas análises de imagens e técnicas de inteligência artificial ou de tomada de decisão, que permitem a identificação e classificação de objetos definidos como imagens.

Segundo NIXON et al. (2012), a importância da visão computacional se destacou com o princípio de que as máquinas (computadores) poderiam ser usadas para simular processamentos complexos de percepção visual - até então, restritos à visão e a outras formas de percepção e cognição exclusivas de seres vivos.

Seguindo o objetivo de identificar objetos em uma imagem, fundamentando-se em análise e processamento de imagens, a Visão Computacional pode ser estruturada de forma sistemática (Figura 5).




Figura 5. Representação sistemática da conceitualização de Visão Computacional

Em resumo, o processo de obtenção das imagens é a etapa na qual a imagem é adquirida para ser utilizada no sistema. Pode ser realizado por sensores ou, de forma digital, por uma câmera. Na fase denominada pré-processamento, utiliza-se a imagem capturada no passo anterior, de forma que ela seja submetida a análises específicas, a fim de remover ou reduzir falhas e imperfeições da imagem.



O processo de segmentação, quando necessário, tem o objetivo de dividir a imagem inicial em vários objetos de interesse, conforme a significância deles para a reconstituição plena da imagem ou partes específicas de interesse.

Já na etapa de extração, são apenas armazenadas as características classificadas como relevantes para o reconhecimento da imagem. A extração é feita via descritores (Figura 3) obtidos de diferentes maneiras, conforme o interesse do pesquisador. Assim, quando finalizado este processo de extração, é possível caracterizar precisamente a importância de cada objeto para o estudo integral da imagem de interesse. Por fim, o reconhecimento e interpretação constituem a aplicação de algoritmos específicos para reconhecer e rotular (identificar conteúdos) nas imagens segundo as características extraídas na etapa anterior.

Adicionalmente, atribui-se (sempre que possível) significado às características para realizar o seu pós-processamento, proporcionando, dessa forma, um sentido prático para a etapa de extração e reconhecimento.



4. Redes convolucionais aplicadas à visão computacional

As Redes Neurais Convolucionais (RNC) atingiram um notável sucesso prático e têm sido largamente adotadas, recentemente, pela comunidade científica relacionada com a área de Visão Computacional (LeCUN et al., 2015). Inicialmente, foram propostas como alternativa viável para solucionar problemas na área de Inteligência Artificial, por meio da introdução de processos de aprendizagem não supervisionados, capazes de construir camadas de detecção de atributos, sem necessitarem de informações pré-rotuladas.



Embora sob o ponto de vista de treinamento a partir de dados não rotulados (BENGIO, 2009) as redes neurais tradicionais ainda sejam consideradas complexas, sob o enfoque de análise de imagens, elas se mostraram muito mais fáceis e atraentes. Portanto, atualmente, têm sido largamente adotadas na área de Visão Computacional.

Em resumo, as RNC foram inspiradas na estrutura do sistema visual. Os primeiros modelos computacionais baseados nessas conectividades locais entre neurônios e em transformações de imagens organizadas hierarquicamente foram encontrados em FUKUSHIMA (1980). Posteriormente, o estado da arte usando a arquitetura de Redes Convolucionais foi alcançado em várias tarefas de reconhecimento de imagens, conforme citação prévia de LeCUN et al. (2015).

Para constituir uma rede neural, os neurônios são agrupados em estruturas denominadas camadas. Elas, por sua vez, são geralmente agrupadas, definindo a profundidade da rede neural. O modo como essas camadas são agrupadas e a forma de aprendizado definem a arquitetura de uma rede neural artificial.


Entre as várias arquiteturas de redes neurais, as Convolucionais têm como uma das características principais o uso de mapas de convolução como conjunto de pesos compartilhados entre os vários neurônios das camadas de convolução.

Sob o ponto de vista teórico, o conceito de convolução é caracterizado por uma operação matemática entre duas funções f e g , produzindo uma terceira função, que pode ser interpretada como uma função modificada de f (PARKER, 2010). No processamento de imagens, sendo a imagem definida como uma função multidimensional, a convolução é útil para detecção de bordas, suavização de imagem e extração de atributos, entre outras aplicações.

A RNC é dividida em uma série de estágios (LeCUN et al., 2015), de forma que os primeiros são constituídos pelas camadas de convolução e pelas camadas de *pooling*.

A camada de convolução é representada como mapas de atributos, os quais são conectados a cada unidade da camada anterior por meio de um conjunto de parâmetros compartilhados entre todas as unidades. Tal compartilhamento é geralmente realizado mediante funções da classe ReLUs (Rectified Linear Units), nas quais os neurônios são avaliados sob o enfoque não-linear, a fim de buscar identificar relações não lineares entre os atributos extraídos da imagem.

Por sua vez, as camadas de *pooling* calculam o máximo local de uma determinada região do mapa de atributos. Assim, são úteis na remoção de valores não máximos, reduzindo a



dimensão da representação dos dados e, conseqüentemente, a computação necessária para as próximas camadas. A partir do empilhamento desses estágios, é possível definir RNC como uma particularidade das redes de aprendizado profundo (*deep learning*).


A arquitetura utilizada por KRIZHEVSKY et al. (2012) no ImageNet representa o marco na utilização de RNC para o reconhecimento de imagens. Esta rede foi definida com 8 camadas, de forma que as 5 primeiras são convolucionais e as 3 últimas são completamente conexas. A saída da última camada alimenta um algoritmo softmax com 1000 classes, o qual foi capaz de proporcionar uma distribuição probabilística ao longo das 1000 classes utilizadas na competição. As particularidades não-linearidades das ReLUs foram utilizadas na saída de todas as camadas convolucionais e completamente conexas.

Segundo KRIZHEVSKY et al. (2012), as imagens originais fornecidas para o treinamento foram acrescidas das reflexões horizontais delas e de recortes das imagens originais e suas reflexões, com o objetivo de ampliar o conjunto de treinamento. Adicionalmente, também foram alteradas as intensidades dos canais RGB (*Red-Green-Blue*) das imagens.



Para reduzir o tempo de treinamento deste conjunto de imagens e, simultaneamente, modelar e eliminar o já reportado problema de *overfitting*, os autores usaram a metodologia de *dropout*. Tal metodologia tende a remover aleatoriamente metade dos neurônios das camadas ocultas, a cada iteração de treinamento, mas readicionando-os na iteração seguinte.

As RNC atualmente assumem um número significativamente superior de camadas, de forma que recentes arquiteturas de RNC têm de 10 a 20 camadas, centenas de milhões de pesos e bilhões de conexões. Graças ao progresso em *hardware*, *software* e algoritmos paralelos, redes como estas, que levariam semanas para serem treinadas, hoje esse trabalho pode ser feito em um período de tempo muito menor.



Referências

BEALE, M. H., M. T. HAGAN, AND H. B. DEMUTH. 2011. Neural Network Toolbox™ MATLAB. http://128.174.199.77/matlab_pdf/nnet.pdf

BENGIO, Y. Learning deep architectures for AI. Foundations and trends in Machine Learning, v2(1), p1-127, 2009. <https://www.amazon.com.br/Learning-Deep-Architectures-Yoshua-Bengio/dp/1601982941>

FUKUSHIMA, K. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position. Biological cybernetics, v36(4), p193-202, 1980. <https://link.springer.com/article/10.1007/BF00344251>

GIANOLA, D., H. OKUT, K. WEIGEL, AND G. ROSA. 2011. Predicting complex quantitative traits with Bayesian neural networks: a case study with Jersey cows and wheat. BMC Genetics 12:87. <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3474182/>

GOODFELLOW, I., POUGET-ABADIE, J., MIRZA, M., XU, B., WARDE-FARLEY, D., OZAIR, S. Generative adversarial nets. In: Advances in neural information processing systems; 2014. p. 2672–2680. <https://papers.nips.cc/paper/2014/hash/5ca3e9b122f61f8f06494c97b1afccf3-Abstract.html>

HASTIE, T., R. TIBSHIRANI, J. FRIEDMAN, AND J. FRANKLIN. 2009. The elements of statistical learning: data mining, inference and prediction. The Mathematical Intelligencer 27:83-85. <https://web.stanford.edu/~hastie/ElemStatLearn/>

KRIZHEVSKY, A., SUTSKEVER, I., HINTON, G.E. ImageNet Classification with Deep Convolutional Neural Networks. Proceedings of Neural Information Processing Systems, p1097-1105, 2012. <https://dl.acm.org/doi/10.1145/3065386>

KONGSRO, J. Estimation of pig weight using a Microsoft Kinect prototype imaging system. 2014. Computers and Electronics in Agriculture, 109 (2014) 32–35. <https://dl.acm.org/doi/10.1016/j.compag.2014.08.008>


LeCUN, Y., BENGIO, Y., HINTON, G. Deep Learning. Nature, v521, p436- 444, 2015. <https://www.nature.com/articles/nature14539>

NIXON, M., NIXON, M.S., AGUADO, A.S. Feature extraction & image processing for computer vision. Academic Press, 2012. <https://www.amazon.com.br/Feature-Extraction-Processing-Computer-Vision/dp/0123965497>

PARKER, J.R. Algorithms for image processing and computer vision. John Wiley & Sons, 2010. <https://www.amazon.com.br/Algorithms-Image-Processing-Computer-Vision/dp/0470643854>

PÉREZ-RODRÍGUEZ, P., D. GIANOLA, K. A. WEIGEL, G. J. M. ROSA, AND J. CROSSA. 2013. Technical Note: An R package for fitting Bayesian regularized neural networks with applications in animal breeding. Journal of Animal Science. 91:3522-3531. <https://pubmed.ncbi.nlm.nih.gov/23658327/>

PEZZUOLO, A., GUARINO, M., SARTORI, L., GONZÁLEZ, L., MARINELLO, F. 2018. On-barn pig weight estimation based on body measurements by a Kinect v1 depth camera. Computers and Electronics in Agriculture. 148. 29-36. <https://dl.acm.org/doi/10.1016/j.compag.2014.08.008>



R CORE TEAM (2020). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. URL <https://www.R-project.org/>.

SZELISKI, R. Computer vision: algorithms and applications. Springer, 2010. <https://szeliski.org/Book/>

POLZEHL, J. , TABELOW, K. Adaptive Smoothing of Digital Images: The R Package *adimpro*. 2007. Journal of Statistical Software. V 19, Issue 1. <https://core.ac.uk/download/pdf/6303152.pdf>

SIMONCELLI EP, OLSHAUSEN BA. Natural image statistics and neural representation. Annu Rev Neurosci. 2001; 24(1):1193–1216, doi: 10.1146/annurev.neuro.24.1.1193. <https://www.annualreviews.org/doi/pdf/10.1146/annurev.neuro.24.1.1193>

STOWERS, J., HAYES, M. AND BAINBRIDGE-SMITH, A. 2011. Altitude control of a quadrotor helicopter using depth map from microsoft kinect sensor., IEEE International Conference on Mechatronics, IEEE, pp. 358 - 362. <https://ieeexplore.ieee.org/document/5971311>

STEFFENS, D.R., DREWS JR, P.L.J., BOTELHO, S.S., MATTOS, V.L.D. Análise exploratória de dados de imagens digitais noturnas. 2019. Scientia Plena, v. 15, n. 4. file:///C:/Users/Usuario/Downloads/Analise_Exploratoria_de_Dados_de_Imagens_Digitais_.pdf

WEBER, A., SALAU, J., HAAS, J.H., JUNGE, W., BAUER, U., HARMS, J., SUHR, O., SCHONROCK, K., ROTHFUS, H., BIELETZKI, S., THALLER, G., 2014. Estimation of backfat thickness using extracted traits from an automatic 3D optical system in lactating Holstein- Friesian cows. Livestock Sci. 165, 129 –137. <https://www.sciencedirect.com/science/article/abs/pii/S1871141314001747>



Coordenadoria de
Educação Aberta e a Distância